

# LABORATORIO\_3

Sergio Alejandro Buitrago Melo  
María Paula Camargo Rincón  
Sergio Alejandro Gaona Díaz

María Alejandra Cabra Arias  
Ana María Chacón Bello  
Juan Esteban García Muete

2025-05-14

## hola mundo

los comandos son (usenlo en la terminal, no en la consola):

git pull origin main git add . git commit -m "comentario" git push origin Tu\_rama

hacen el pull request

-se pasan a main local -git pull origin main -luego a su rama local -git merge main -git push origin su rama

Laboratorio #2

Librerías y preliminares:

```
#librerías
```

```
library(readxl)  
library(FactoMineR)  
library(ggplot2)  
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```
library(dplyr)
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
## filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
## intersect, setdiff, setequal, union
```

```
library(tibble)
```

```
library(sqldf)
```

```
## Cargando paquete requerido: gsubfn
```

```
## Cargando paquete requerido: proto

## Cargando paquete requerido: RSQLite
```

```
#base de datos
ciudades <- read_xlsx("Ciudades.xlsx")
#summary(ciudades)
View(ciudades)
```


Se realizarán los distintos ACP con las variables de RH e INFRA


```
#base de datos RH+INFRA
ciudadest<-ciudades[,c(1:15,21:30)]
# Ahora convierte esa columna en rownames
ciudadest <- column_to_rownames(ciudadest, var = "CIUDADES")
View(ciudadest)
```

PRIMER PUNTO

```
#ACP todas las variables que le corresponden####
acp1<-PCA(ciudadest,ncp = 7)
```

```
## Warning: ggrepel: 1 unlabeled data points (too many overlaps). Consider
## increasing max.overlaps
```





*# Contiene los auto valores correspondientes a los componentes principales*  
`acp1$eig`

##	eigenvalue	percentage of variance	cumulative percentage of variance
## comp 1	6.143979350	25.59991396	25.59991
## comp 2	3.644318791	15.18466163	40.78458
## comp 3	2.950521777	12.29384074	53.07842
## comp 4	2.723578886	11.34824536	64.42666
## comp 5	1.735004053	7.22918355	71.65585
## comp 6	1.639276649	6.83031937	78.48616
## comp 7	1.134367266	4.72653028	83.21269
## comp 8	0.952165621	3.96735675	87.18005
## comp 9	0.845039806	3.52099919	90.70105
## comp 10	0.568206619	2.36752758	93.06858
## comp 11	0.496018133	2.06674222	95.13532
## comp 12	0.366954836	1.52897848	96.66430
## comp 13	0.306467492	1.27694788	97.94125
## comp 14	0.226007063	0.94169610	98.88294
## comp 15	0.100129109	0.41720462	99.30015
## comp 16	0.057199198	0.23832999	99.53848
## comp 17	0.042294765	0.17622819	99.71471
## comp 18	0.031711599	0.13213166	99.84684
## comp 19	0.021900878	0.09125366	99.93809
## comp 20	0.010023059	0.04176275	99.97985
## comp 21	0.004835049	0.02014604	100.00000

```
# El 83 por ciento de la varianza
acp1$eig[,3]
```

```
##      comp 1      comp 2      comp 3      comp 4      comp 5      comp 6      comp 7      comp 8
## 25.59991 40.78458 53.07842 64.42666 71.65585 78.48616 83.21269 87.18005
##      comp 9      comp 10      comp 11      comp 12      comp 13      comp 14      comp 15      comp 16
## 90.70105 93.06858 95.13532 96.66430 97.94125 98.88294 99.30015 99.53848
##      comp 17      comp 18      comp 19      comp 20      comp 21
## 99.71471 99.84684 99.93809 99.97985 100.00000
```

Siguiendo el criterio de los valores propios mayores a 1, se obtienen 7 componentes principales, de las cuales explican un 83% de la varianza total.

Por otro lado la suma de los valores propios de estos componente es igual al número de variables que estamos manejando.

```
#al sumar la columna de los eigenvalue da 24
sum(acp1$eig[,1])
```

```
## [1] 24
```

```
#coordenadas de las variables
acp1$var$coord
```

```
##      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## RH_1      0.39326416 -0.16582617 0.79808707 0.234443904 0.03870311
## RH_2      -0.73318056 0.30910863 0.24834687 0.295451362 -0.13622339
## RH_5      -0.73829548 0.47923668 0.28171147 -0.101211477 -0.14542959
## RH_6      0.27009928 0.78569503 -0.14262801 0.065820983 0.19208678
## RH_7      0.65391553 -0.05609103 0.61819704 0.185758272 0.09978721
## RH_8      -0.42353084 0.66615482 0.24434105 0.168470217 0.15409973
## RH_9      0.67000755 -0.18481789 0.18727088 0.164122673 0.03335124
## RH_10     0.05867078 -0.20747753 -0.18407648 -0.559808670 0.50690189
## RH_11     0.19745370 0.12168754 0.22078089 0.004902492 -0.55512379
## RH_12     -0.55248164 0.27277774 0.30421092 0.051980537 0.06233117
## RH_13     -0.09305287 0.11713539 -0.33640969 0.821218569 0.34941540
## RH_14     0.16938965 0.18224626 -0.50837225 0.632713120 0.02554166
## RH_15     0.23534090 0.22514611 -0.15862851 -0.043439229 0.33033865
## RH_16     -0.21174190 -0.80781025 -0.24491096 0.184368443 0.01087989
## INFRA_25  0.91574462 -0.06385140 0.15085539 -0.019583543 0.18640140
## INFRA_26  0.58559310 0.15503623 -0.13338967 -0.193634112 0.45484585
## INFRA_27  0.57675110 0.33826657 -0.09625905 -0.481188041 -0.33679031
## INFRA_28  0.62174339 0.08309287 -0.14615670 -0.423228096 -0.42681853
## INFRA_30  0.13008484 -0.21238227 -0.17355059 0.489006179 -0.40760158
## INFRA_31  0.58251848 0.37273449 -0.47121912 0.247924906 -0.09799203
## INFRA_32  0.59448410 0.21046931 -0.36289112 0.340194841 -0.31102191
## INFRA_33  0.03432868 -0.77093458 0.37373834 0.338405521 -0.00279060
## INFRA_37  0.77264888 0.04596188 0.37454936 0.190432249 0.10077022
## INFRA_38 -0.28993642 -0.58012722 -0.55526987 -0.185891591 -0.03510750
##      Dim.6      Dim.7
## RH_1      -0.186970829 0.09711721
## RH_2      0.187059555 0.14579669
```

```
## RH_5      0.038259715  0.07840561
## RH_6     -0.161775467 -0.12790827
## RH_7      0.032767999  0.11098763
## RH_8     -0.281247035 -0.23116490
## RH_9      0.195707854  0.16811725
## RH_10    -0.004230834  0.39212288
## RH_11     0.636168752 -0.26133285
## RH_12     0.313790688  0.49403548
## RH_13    -0.003822078  0.05054391
## RH_14    -0.177522243  0.18840110
## RH_15     0.550233297  0.34119418
## RH_16     0.139008709 -0.13241458
## INFRA_25  0.043531483  0.03401149
## INFRA_26 -0.064865708 -0.35067018
## INFRA_27 -0.257353066  0.20863439
## INFRA_28 -0.223418106  0.22175271
## INFRA_30 -0.514782517  0.29924306
## INFRA_31  0.229991839  0.10928353
## INFRA_32  0.294938030 -0.08347409
## INFRA_33 -0.064945043  0.04349121
## INFRA_37  0.102692039 -0.14001836
## INFRA_38  0.156578722 -0.04739415
```

```
#correlaciones variable factor
acpl$var$cor
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## RH_1      0.39326416 -0.16582617  0.79808707  0.234443904  0.03870311
## RH_2     -0.73318056  0.30910863  0.24834687  0.295451362 -0.13622339
## RH_5     -0.73829548  0.47923668  0.28171147 -0.101211477 -0.14542959
## RH_6      0.27009928  0.78569503 -0.14262801  0.065820983  0.19208678
## RH_7      0.65391553 -0.05609103  0.61819704  0.185758272  0.09978721
## RH_8     -0.42353084  0.66615482  0.24434105  0.168470217  0.15409973
## RH_9      0.67000755 -0.18481789  0.18727088  0.164122673  0.03335124
## RH_10     0.05867078 -0.20747753 -0.18407648 -0.559808670  0.50690189
## RH_11     0.19745370  0.12168754  0.22078089  0.004902492 -0.55512379
## RH_12    -0.55248164  0.27277774  0.30421092  0.051980537  0.06233117
## RH_13    -0.09305287  0.11713539 -0.33640969  0.821218569  0.34941540
## RH_14     0.16938965  0.18224626 -0.50837225  0.632713120  0.02554166
## RH_15     0.23534090  0.22514611 -0.15862851 -0.043439229  0.33033865
## RH_16    -0.21174190 -0.80781025 -0.24491096  0.184368443  0.01087989
## INFRA_25  0.91574462 -0.06385140  0.15085539 -0.019583543  0.18640140
## INFRA_26  0.58559310  0.15503623 -0.13338967 -0.193634112  0.45484585
## INFRA_27  0.57675110  0.33826657 -0.09625905 -0.481188041 -0.33679031
## INFRA_28  0.62174339  0.08309287 -0.14615670 -0.423228096 -0.42681853
## INFRA_30  0.13008484 -0.21238227 -0.17355059  0.489006179 -0.40760158
## INFRA_31  0.58251848  0.37273449 -0.47121912  0.247924906 -0.09799203
## INFRA_32  0.59448410  0.21046931 -0.36289112  0.340194841 -0.31102191
## INFRA_33  0.03432868 -0.77093458  0.37373834  0.338405521 -0.00279060
## INFRA_37  0.77264888  0.04596188  0.37454936  0.190432249  0.10077022
## INFRA_38 -0.28993642 -0.58012722 -0.55526987 -0.185891591 -0.03510750
##          Dim.6      Dim.7
## RH_1     -0.186970829  0.09711721
## RH_2      0.187059555  0.14579669
```

```
## RH_5      0.038259715  0.07840561
## RH_6     -0.161775467 -0.12790827
## RH_7      0.032767999  0.11098763
## RH_8     -0.281247035 -0.23116490
## RH_9      0.195707854  0.16811725
## RH_10    -0.004230834  0.39212288
## RH_11     0.636168752 -0.26133285
## RH_12     0.313790688  0.49403548
## RH_13    -0.003822078  0.05054391
## RH_14    -0.177522243  0.18840110
## RH_15     0.550233297  0.34119418
## RH_16     0.139008709 -0.13241458
## INFRA_25  0.043531483  0.03401149
## INFRA_26 -0.064865708 -0.35067018
## INFRA_27 -0.257353066  0.20863439
## INFRA_28 -0.223418106  0.22175271
## INFRA_30 -0.514782517  0.29924306
## INFRA_31  0.229991839  0.10928353
## INFRA_32  0.294938030 -0.08347409
## INFRA_33 -0.064945043  0.04349121
## INFRA_37  0.102692039 -0.14001836
## INFRA_38  0.156578722 -0.04739415
```

*#basicamente estas covarianzas nos habla de como las variables  
#se relacionan con los factores y en que medida los construye*

*#cosenos cuadrados de las variables*  
acpl\$var\$cos2

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## RH_1      0.154656696 0.027498320 0.636942970 5.496394e-02 1.497931e-03
## RH_2      0.537553740 0.095548146 0.061676169 8.729151e-02 1.855681e-02
## RH_5      0.545080211 0.229667800 0.079361355 1.024376e-02 2.114977e-02
## RH_6      0.072953619 0.617316674 0.020342749 4.332402e-03 3.689733e-02
## RH_7      0.427605517 0.003146204 0.382167574 3.450614e-02 9.957487e-03
## RH_8      0.179378374 0.443762241 0.059702551 2.838221e-02 2.374673e-02
## RH_9      0.448910111 0.034157653 0.035070381 2.693625e-02 1.112305e-03
## RH_10     0.003442260 0.043046925 0.033884152 3.133857e-01 2.569495e-01
## RH_11     0.038987965 0.014807857 0.048744202 2.403443e-05 3.081624e-01
## RH_12     0.305235968 0.074407698 0.092544286 2.701976e-03 3.885175e-03
## RH_13     0.008658837 0.013720700 0.113171481 6.743999e-01 1.220911e-01
## RH_14     0.028692855 0.033213700 0.258442348 4.003259e-01 6.523765e-04
## RH_15     0.055385341 0.050690770 0.025163006 1.886967e-03 1.091236e-01
## RH_16     0.044834631 0.652557406 0.059981380 3.399172e-02 1.183720e-04
## INFRA_25  0.838588204 0.004077001 0.022757348 3.835152e-04 3.474548e-02
## INFRA_26  0.342919275 0.024036232 0.017792805 3.749417e-02 2.068847e-01
## INFRA_27  0.332641828 0.114424269 0.009265805 2.315419e-01 1.134277e-01
## INFRA_28  0.386564841 0.006904425 0.021361782 1.791220e-01 1.821741e-01
## INFRA_30  0.016922066 0.045106228 0.030119807 2.391270e-01 1.661390e-01
## INFRA_31  0.339327783 0.138931002 0.222047457 6.146676e-02 9.602439e-03
## INFRA_32  0.353411344 0.044297329 0.131689966 1.157325e-01 9.673463e-02
## INFRA_33  0.001178458 0.594340122 0.139680347 1.145183e-01 7.787447e-06
## INFRA_37  0.596986299 0.002112494 0.140287226 3.626444e-02 1.015464e-02
```

```

## INFRA_38 0.084063126 0.336547590 0.308324632 3.455568e-02 1.232536e-03
##          Dim.6      Dim.7
## RH_1      3.495809e-02 0.009431752
## RH_2      3.499128e-02 0.021256673
## RH_5      1.463806e-03 0.006147439
## RH_6      2.617130e-02 0.016360524
## RH_7      1.073742e-03 0.012318254
## RH_8      7.909989e-02 0.053437209
## RH_9      3.830156e-02 0.028263409
## RH_10     1.789995e-05 0.153760356
## RH_11     4.047107e-01 0.068294856
## RH_12     9.846460e-02 0.244071057
## RH_13     1.460828e-05 0.002554687
## RH_14     3.151415e-02 0.035494976
## RH_15     3.027567e-01 0.116413470
## RH_16     1.932342e-02 0.017533620
## INFRA_25  1.894990e-03 0.001156782
## INFRA_26  4.207560e-03 0.122969575
## INFRA_27  6.623060e-02 0.043528308
## INFRA_28  4.991565e-02 0.049174266
## INFRA_30  2.650010e-01 0.089546408
## INFRA_31  5.289625e-02 0.011942891
## INFRA_32  8.698844e-02 0.006967923
## INFRA_33  4.217859e-03 0.001891486
## INFRA_37  1.054565e-02 0.019605140
## INFRA_38  2.451690e-02 0.002246205

```

acp1\$ind\$cos2

```

##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## Armenia      0.1206007640 0.0168217787 0.021779358 0.3019426841 0.2704638532
## Barranquilla 0.0207042054 0.0303278245 0.221422032 0.0111212344 0.1113213530
## Bogotá, D.C. 0.1794727575 0.1063446968 0.565927253 0.0635298004 0.0000340343
## Bucaramanga  0.5427631819 0.0064187423 0.003692434 0.1149305948 0.0798545780
## Cali         0.3067947356 0.0012145212 0.015892489 0.0532729664 0.0380979951
## Cartage      0.2475537126 0.0111368877 0.009736382 0.0395270649 0.1064509824
## Cúcuta       0.0143461211 0.1760205372 0.037801400 0.0934816370 0.0128602994
## Ibagué       0.0417699395 0.0628401251 0.039752977 0.0013292354 0.0652762285
## Manizales    0.4604777790 0.0045658914 0.131313338 0.0884271025 0.1732593714
## Medellín     0.2435365819 0.1580542500 0.184148380 0.0330012039 0.0338069406
## Montería     0.4781261740 0.0262715389 0.016876090 0.0143838717 0.0389391166
## Neiva        0.2030603529 0.0430952808 0.130305739 0.0058727771 0.2806353428
## Pasto        0.0003247286 0.0092764049 0.012439226 0.0030805639 0.1709345690
## Pereira     0.3206768091 0.0313302849 0.022421798 0.0252986966 0.0890436286
## Popayán      0.0724306380 0.0622295718 0.188675624 0.1526564059 0.0363637558
## Riohacha     0.6968575220 0.0806839002 0.070740650 0.0001321617 0.0012093339
## San Arés     0.0974063184 0.8102345341 0.025555710 0.0015368945 0.0016235918
## Santa Marta  0.3572210137 0.0002494462 0.006624299 0.0592938844 0.0129169731
## Sincelejo    0.0315000405 0.1674191579 0.118486166 0.0224166858 0.1445611772
## Tunja        0.0011011321 0.0051722166 0.090891738 0.0002022689 0.1522900451
## Valledupar   0.6180701531 0.0247042873 0.085100124 0.0003829994 0.1594315528
## Villavicencio 0.0291402485 0.0205999297 0.107140924 0.7545828937 0.0765873993
##          Dim.6      Dim.7
## Armenia      2.735963e-03 8.819147e-02


```

```
## Barranquilla 7.571316e-04 3.946223e-04
## Bogotá, D.C. 3.386988e-02 2.193132e-02
## Bucaramanga 1.631924e-02 9.188270e-03
## Cali 9.401429e-02 1.374251e-02
## Cartage 3.315980e-01 7.089978e-03
## Cúcuta 1.150180e-01 1.290014e-02
## Ibagué 3.851752e-01 2.506309e-02
## Manizales 1.894157e-02 8.690660e-04
## Medellín 5.720053e-03 2.106959e-01
## Montería 1.089441e-01 2.305072e-01
## Neiva 8.523734e-02 9.877403e-02
## Pasto 1.339590e-01 7.011103e-02
## Pereira 2.533450e-01 2.850348e-03
## Popayán 7.200734e-03 6.817677e-02
## Riohacha 6.193703e-02 4.796880e-02
## San Arés 9.919473e-03 1.264737e-02
## Santa Marta 4.206732e-05 8.464990e-03
## Sincelejo 2.568069e-01 2.861832e-02
## Tunja 3.616425e-02 7.332659e-02
## Valledupar 2.481085e-02 9.329342e-04
## Villavicencio 2.363053e-04 4.819520e-06
```

Gràfics primer punto

```
# Gráfico de individuos
G11<-fviz_pca_ind(acp1, geom = 'text',
  col.ind = "cos2", # calidad de representación
  gradient.cols = c("darkgreen", "#FC4E07"),
  repel = TRUE
)
G11
```





En el gráfico podemos observar que destacan 4 ciudades, San Andrés, Riohacha, Valledupar y Bucaramanga, lo que da a entender que la mayor parte de variabilidad de esas ciudades esta siendo explicada por las componentes 1 y 2 (Dim1 y Dim2), además también se puede ver por cuál de las dimensiones parecen ser mejor representadas, por ejemplo, Valledupar y Bucaramanga parecen estar mejor representados por la componente 1 que San Andrés y Riohacha, los cuales parecen estar mejor respresentados por la componente 2

```
cos2_ind_1 <- as.data.frame(acp1$ind$cos2)
cos2_ind_1_dim1 <- cos2_ind_1 %>% select(Dim.1,Dim.2) %>% mutate(cos2_total = rowSums(across(everything)))
arrange(desc(cos2_total))
```

A continuación se podrán ver los valores de los primeros 4  $\cos^2$  totales más altos:

Ciudad	$\cos^2$ Dim.1	$\cos^2$ Dim.2	$\cos^2$ total
San Andrés	0.09	0.81	0.90
Riohacha	0.69	0.08	0.77
Valledupar	0.62	0.02	0.64
Bucaramanga	0.54	0.00	0.54

Como se mencionó anteriormente hay ciudades que destacan por componentes.

```
# Crear data frame con la dimensión de mayor cos2 por ciudad
tabla_max_cos2 <- cos2_ind_1 %>%
  as.data.frame() %>%
  mutate(
```

```

ciudad = rownames(.),
mejor_componente = colnames(cos2_ind_1)[max.col(., ties.method = "first")],
max_cos2 = apply(., 1, max)
) %>%
select(ciudad, mejor_componente, max_cos2)
tabla_max_cos2

```

```

##              ciudad mejor_componente max_cos2
## Armenia          Armenia          Dim.4 0.3019427
## Barranquilla      Barranquilla          Dim.3 0.2214220
## Bogotá, D.C.      Bogotá, D.C.          Dim.3 0.5659273
## Bucaramanga        Bucaramanga          Dim.1 0.5427632
## Cali               Cali              Dim.1 0.3067947
## Cartage            Cartage            Dim.6 0.3315980
## Cúcuta             Cúcuta             Dim.2 0.1760205
## Ibagué             Ibagué             Dim.6 0.3851752
## Manizales          Manizales          Dim.1 0.4604778
## Medellín           Medellín          Dim.1 0.2435366
## Montería           Montería          Dim.1 0.4781262
## Neiva              Neiva              Dim.5 0.2806353
## Pasto              Pasto              Dim.5 0.1709346
## Pereira            Pereira            Dim.1 0.3206768
## Popayán            Popayán            Dim.3 0.1886756
## Riohacha           Riohacha           Dim.1 0.6968575
## San Arés           San Arés           Dim.2 0.8102345
## Santa Marta        Santa Marta        Dim.1 0.3572210
## Sincelejo          Sincelejo          Dim.6 0.2568069
## Tunja              Tunja              Dim.5 0.1522900
## Valledupar         Valledupar         Dim.1 0.6180702
## Villavicencio      Villavicencio      Dim.4 0.7545829

```

A continuación una tabla que dice cuantas veces la componente represento mejor al individuo, es decir la componente que tenía el  $\cos^2$  más alto entre todas las componentes.

```

tabla_max_cos2 %>% group_by(mejor_componente) %>% summarise(conteo=n()) %>% arrange(desc(conteo))

```

```

## # A tibble: 6 x 2
##   mejor_componente conteo
##   <chr>           <int>
## 1 Dim.1             9
## 2 Dim.3             3
## 3 Dim.5             3
## 4 Dim.6             3
## 5 Dim.2             2
## 6 Dim.4             2

```


Mejor componente	Conteo
Dim.1	9
Dim.2	2
Dim.3	3

Mejor componente	Conteo
Dim.4	2
Dim.5	2
Dim.6	3

Podemos ver que la componente 1 que explica aproximadamente el 25.6% de variabilidad de la población es la misma que logra representar mejor a 9 ciudades de 22 en total.

Aunque las componentes 3,5,6 individualmente expliquen un porcentaje menor que las componentes 1 y 2, en la tabla se evidencia que hay individuos que están mejor explicados y representados en estos componentes menores.

```
G12<-fviz_pca_var(acp1,
  col.var = 'red',
  alpha.var = 0.5,
  select.var = list(contrib = 7),
  repel = TRUE,
  col.quanti.sup = 'darkgrey'
)
G12
```




```
# 6. Biplot (variables + individuos)
G13<-fviz_pca_biplot(acp1,
  col.ind = "cos2",
```

```

    gradient.cols = c("darkgreen", "red"),
    col.var = "darkblue",
    select.var = list(contrib = 7),
    geom = "text",
    repel = T,
    col.quanti.sup = 'darkgrey'
  )
G13

```



Al observar el plano, tres ciudades se destacan por su lejanía respecto al origen: Bogotá (3), San Andrés (17) y Riohacha (16), lo cual indica que presentan características particulares frente a las variables consideradas.


San Andrés (17) se ubica en el tercer cuadrante, con valores negativos en ambas dimensiones. Esto sugiere limitaciones importantes en infraestructura y educación (por ejemplo, baja población, baja cobertura educativa y débil acceso a internet y telefonía), explicables por su condición insular.


Bogotá (3) aparece en el cuarto cuadrante, asociada positivamente con variables como INFRA\_25 (líneas telefónicas) e INFRA\_37 (internet), lo que refleja su alta conectividad y desarrollo tecnológico, coherente con su papel como capital.

Riohacha (16) se encuentra en el segundo cuadrante, con una fuerte relación negativa respecto a las variables de infraestructura tecnológica, lo que la posiciona como una de las ciudades más rezagadas en este aspecto.

## SEGUNDO PUNTO

```
acp2<-PCA(ciudadest, quanti.sup = c(1:14))
```





```
#Solo las variables INFRA_25 a INFRA_38
 #(columnas 15 a 24) serán activas.
#Las variables RH_* (1 a 14) no se usan para
#construir los ejes principales, pero se proyectan
#en el plano factorial para ser interpretadas.
```

```
#contiene los auto valores correspondientes a los componentes principales
acp2$eig
```

```
##      eigenvalue percentage of variance cumulative percentage of variance
## comp 1  3.73989557          37.3989557          37.39896
## comp 2  1.55392842          15.5392842          52.93824
## comp 3  1.44763393          14.4763393          67.41458
## comp 4  1.10618953          11.0618953          78.47647
## comp 5  1.02559925          10.2559925          88.73247
## comp 6  0.52558475           5.2558475          93.98831
## comp 7  0.28734095           2.8734095          96.86172
## comp 8  0.19940455           1.9940455          98.85577
## comp 9  0.08526143           0.8526143          99.70838
## comp 10 0.02916163           0.2916163         100.00000
```

```
#al sumar la columna de los eigenvalue da 10
sum(acp2$eig[,1])
```

```
## [1] 10
```

```
#la columna de porcentajes de varianza acumulados
#nos muestra que tan importantes son los primeros componentes
# y es notable como con los primeros 5 ya se acumula
# el 88 porciento de la varianza
acp2$eig[c(1:5),c(1,3)]
```

```
##          eigenvalue cumulative percentage of variance
## comp 1    3.739896                                37.39896
## comp 2    1.553928                                52.93824
## comp 3    1.447634                                67.41458
## comp 4    1.106190                                78.47647
## comp 5    1.025599                                88.73247
```

```
#coordenadas de las variables
acp2$var$coord
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## INFRA_25  0.82657707  0.38050074 -0.2133359  0.08213467  0.16151727
## INFRA_26  0.60426012 -0.06343287 -0.5120243 -0.03094806  0.33777561
## INFRA_27  0.75167757 -0.37613407  0.1569072  0.48413257 -0.03703933
## INFRA_28  0.74857470 -0.21533667  0.3277062  0.48501239  0.14985208
## INFRA_30  0.06352942  0.32015548  0.7698038  0.08783533 -0.27664414
## INFRA_31  0.67559759 -0.22729549  0.2420077 -0.54809721 -0.07556691
## INFRA_32  0.68414019  0.03360157  0.3554094 -0.51667260  0.05895429
## INFRA_33 -0.22701374  0.82664856  0.2180315  0.17665952  0.29193043
## INFRA_37  0.68896104  0.58803751 -0.2401200 -0.08573810 -0.07411593
## INFRA_38 -0.33381722 -0.18124393  0.3539277 -0.12340378  0.82774211
```

```
#correlaciones variable factor
acp2$var$cor
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## INFRA_25  0.82657707  0.38050074 -0.2133359  0.08213467  0.16151727
## INFRA_26  0.60426012 -0.06343287 -0.5120243 -0.03094806  0.33777561
## INFRA_27  0.75167757 -0.37613407  0.1569072  0.48413257 -0.03703933
## INFRA_28  0.74857470 -0.21533667  0.3277062  0.48501239  0.14985208
## INFRA_30  0.06352942  0.32015548  0.7698038  0.08783533 -0.27664414
## INFRA_31  0.67559759 -0.22729549  0.2420077 -0.54809721 -0.07556691
## INFRA_32  0.68414019  0.03360157  0.3554094 -0.51667260  0.05895429
## INFRA_33 -0.22701374  0.82664856  0.2180315  0.17665952  0.29193043
## INFRA_37  0.68896104  0.58803751 -0.2401200 -0.08573810 -0.07411593
## INFRA_38 -0.33381722 -0.18124393  0.3539277 -0.12340378  0.82774211
```

```
#basicamente estas covarianzas nos habla de como las variables
#se relacionan con los factores y en que medida los construye
```

```
#cosenos cuadrados de las variables
acp2$var$cos2
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## INFRA_25  0.683229645  0.144780812  0.04551221  0.0067461047  0.026087830
```

```
## INFRA_26 0.365130298 0.004023729 0.26216891 0.0009577821 0.114092360
## INFRA_27 0.565019166 0.141476835 0.02461986 0.2343843481 0.001371912
## INFRA_28 0.560364077 0.046369880 0.10739136 0.2352370211 0.022455645
## INFRA_30 0.004035987 0.102499532 0.59259786 0.0077150444 0.076531981
## INFRA_31 0.456432105 0.051663240 0.05856772 0.3004105567 0.005710358
## INFRA_32 0.468047795 0.001129065 0.12631586 0.2669505712 0.003475609
## INFRA_33 0.051535239 0.683347846 0.04753774 0.0312085843 0.085223378
## INFRA_37 0.474667317 0.345788119 0.05765760 0.0073510226 0.005493171
## INFRA_38 0.111433937 0.032849363 0.12526482 0.0152284928 0.685157007
```

```
var_contrib <- data.frame(acp2$var$contrib)


top5_vars <- rownames(var_contrib)[order(var_contrib$Dim.1 + var_contrib$Dim.2, decreasing = TRUE)][1:5]
sup_vars <- rownames(acp2$quanti.sup$coord)
all_vars <- c(top5_vars, sup_vars)
s2<-acp2$eig
sum(s2[,1])
```

```
## [1] 10
```

Gràfics punto#2:

```
# Gráfico de individuos
G21<-fviz_pca_ind(acp2,
  col.ind = "cos2", # calidad de representación
  gradient.cols = c("darkgreen", "red"),
  repel = TRUE
)
G21
```





En el gráfico podemos observar que destacan 3 ciudades, Bogotá,D.C., Riohacha y Valledupar, lo que da a entender que la mayor parte de variabilidad de esas ciudades esta siendo explicada por las componentes 1 y 2 (Dim1 y Dim2), además también se puede ver por cuál de las dimensiones parecen ser mejor representadas, por ejemplo, Valledupar y Riohacha parecen estar mejor representados por la componente 1 que San Bogotá,D.C., la cual parece estar mejor respresenta por la componente 2

```
cos2_ind_2 <- as.data.frame(acp2$ind$cos2)
cos2_ind_2_dim1 <- cos2_ind_2 %>% select(Dim.1,Dim.2) %>% mutate(cos2_total = rowSums(across(everything)))
arrange(desc(cos2_total))
```

A continuación se podrán ver los valores de los primeros 3  $\cos^2$  totales más altos:

Ciudad	$\cos^2$ Dim.1	$\cos^2$ Dim.2	$\cos^2$ total
Riohacha	0.77	0.04	0.81
Bogotá, D.C.	0.04	0.75	0.79
Valledupar	0.71	0.08	0.79

Como se mencionó anteriormente hay ciudades que destacan por componentes.

```
# Crear data frame con la dimensión de mayor cos2 por ciudad
tabla_max_cos2_2 <- cos2_ind_2 %>%
  as.data.frame() %>%
  mutate(
    ciudad = rownames(.),
    mejor_componente = colnames(cos2_ind_2)[max.col(., ties.method = "first")],
```

```

    max_cos2 = apply(., 1, max)
  ) %>%
  select(ciudad, mejor_componente, max_cos2)
tabla_max_cos2_2

```

```

##              ciudad mejor_componente max_cos2
## Armenia          Armenia          Dim.5 0.3406184
## Barranquilla    Barranquilla          Dim.2 0.4314598
## Bogotá, D.C.    Bogotá, D.C.          Dim.2 0.7576747
## Bucaramanga     Bucaramanga          Dim.1 0.4394121
## Cali            Cali              Dim.1 0.4458738
## Cartage         Cartage           Dim.1 0.5546474
## Cúcuta          Cúcuta            Dim.2 0.3564270
## Ibagué          Ibagué            Dim.4 0.2941408
## Manizales       Manizales          Dim.1 0.4933737
## Medellín        Medellín          Dim.3 0.5211847
## Montería        Montería          Dim.1 0.5791771
## Neiva           Neiva             Dim.1 0.4834851
## Pasto           Pasto             Dim.5 0.2329005
## Pereira         Pereira           Dim.1 0.5033667
## Popayán         Popayán           Dim.2 0.2133196
## Riohacha        Riohacha          Dim.1 0.7747932
## San Arés        San Arés          Dim.1 0.4003900
## Santa Marta     Santa Marta        Dim.1 0.3111148
## Sincelejo       Sincelejo          Dim.3 0.4362759
## Tunja           Tunja             Dim.2 0.3555548
## Valledupar      Valledupar         Dim.1 0.7136357
## Villavicencio   Villavicencio      Dim.4 0.6366388

```

A continuación una tabla que dice cuantas veces la componente represento mejor al individuo, es decir la componente que tenía el  $\cos^2$  más alto entre todas las componentes.

```

tabla_max_cos2_2 %>% group_by(mejor_componente) %>% summarise(conteo=n()) %>% arrange(desc(conteo))

```

```

## # A tibble: 5 x 2
##   mejor_componente conteo
##   <chr>           <int>
## 1 Dim.1             11
## 2 Dim.2              5
## 3 Dim.3              2
## 4 Dim.4              2
## 5 Dim.5              2

```


Mejor componente	Conteo
Dim.1	11
Dim.2	5
Dim.3	2
Dim.4	2
Dim.5	2

Podemos ver que la componente 1 que explica aproximadamente el 37.4% de variabilidad de la población es la misma que logra representar mejor a 11 ciudades de 22 en total, es decir a la mitad. Podemos ver que en

los siguientes componentes va disminuyendo la cantidad de individuos que son mejor representados dentro de estos a comparación de los demás.


```
G22<-fviz_pca_var(acp2,
  col.var = "darkblue",
  gradient.cols = c("darkgreen", "#E7B800", "red"),
  alpha.var = 0.5,
  repel = TRUE,
  col.quanti.sup = 'darkgrey',
  select.var = list(name =c(all_vars)),
  title = 'Variables y suplementarias'
)
```

G22



```
G23<-fviz_pca_biplot(acp2,
  col.ind = "cos2",
  gradient.cols = c("darkgreen", "red"),
  col.var = "darkblue",
  repel = T,
  col.quanti.sup = 'darkgrey',
  select.var = list(name =c(all_vars)),
  title = 'Biplot'
)
```

G23



Al revisar las coordenadas 3 individuos resaltan al ojo, Bogotá (3), San Andrés (17) y Riohacha (16) por ser los individuos más alejados del origen de nuestro plano, esto nos indica singularidades y posibles aspectos a destacar de estas ciudades.

Al revisar a San Andrés vemos que este guarda una relación negativa con las variables INFRA 27/28 (acueducto y alcantarillado cada 10000 habitantes) esto explicable fácilmente gracias a su baja población y su geografía de isla que dificulta la construcción de infraestructura pública como alcantarillado.


Por el lado de la capital vemos su alto posicionamiento en la dimensión 2, y a pesar que existe una relación destacable con INFRA 37/25 (clientes de internet y líneas telefónicas cada 10000 habitantes), el rasgo más importante de este individuo es su alta posición en el eje Y, explicada en parte gracias a la variable de carga aérea (INFRA 33) donde Bogotá es líder seguido de cerca de San Andrés.


En el tercer cuadrante encontramos a Riohacha, el cual es representado de manera negativa con respecto a nuestras variables de telecomunicaciones siendo este el individuo más destacable del lado negativo del eje X

### TERCER PUNTO

```
acp3<-PCA(ciudadest, quanti.sup = c(15:24), ncp = 6)
```

```
## Warning: ggrepel: 2 unlabeled data points (too many overlaps). Consider
## increasing max.overlaps
```





```
#Esto hace lo opuesto: trata las variables de
#infraestructura (15 a 24) como suplementarias y
#las variables RH (1 a 14) como activas.
```

```
#contiene los auto valores correspondientes a los componentes principales
acp3$eig
```

##	eigenvalue	percentage of variance	cumulative percentage of variance
## comp 1	3.57145227	25.51037333	25.51037
## comp 2	2.23904563	15.99318305	41.50356
## comp 3	2.07159426	14.79710185	56.30066
## comp 4	1.60270922	11.44792298	67.74858
## comp 5	1.25832699	8.98804991	76.73663
## comp 6	1.19179090	8.51279212	85.24942
## comp 7	0.77121137	5.50865263	90.75808
## comp 8	0.46142015	3.29585818	94.05393
## comp 9	0.32761648	2.34011768	96.39405
## comp 10	0.21525724	1.53755171	97.93160
## comp 11	0.12879153	0.91993949	98.85154
## comp 12	0.09416088	0.67257769	99.52412
## comp 13	0.05382938	0.38449557	99.90862
## comp 14	0.01279373	0.09138382	100.00000

```
#al sumar la columna de los eigenvalue da 14
sum(acp3$eig[,1])
```

```
## [1] 14
```

```
#la columna de porcentajes de varianza acumulados
#nos muestra que tan importantes son los primeros componentes
# y es notable como con los primeros 6 ya se acumula
# el 85 porciento de la varianza
acp3$eig[c(1:6),c(1,3)]
```

```
##          eigenvalue cumulative percentage of variance
## comp 1      3.571452                      25.51037
## comp 2      2.239046                      41.50356
## comp 3      2.071594                      56.30066
## comp 4      1.602709                      67.74858
## comp 5      1.258327                      76.73663
## comp 6      1.191791                      85.24942
```

```
#coordenadas de las variables
acp3$var$coord
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5      Dim.6
## RH_1 -0.35693798  0.70877743 -0.03696321  0.29065674  0.001408176  0.41343738
## RH_2  0.81930164  0.19450143 -0.10637763  0.37891761  0.192633367  0.05114370
## RH_5  0.90417056  0.20834627 -0.27356525 -0.04550233  0.012177864  0.06451571
## RH_6  0.20854441  0.30278075  0.62998230 -0.55512354 -0.174660976 -0.15421996
## RH_7 -0.51603493  0.71791876  0.10571827  0.09082143  0.134489129  0.25757944
## RH_8  0.79360603  0.30489947  0.26180205 -0.08636297 -0.243592220  0.18660305
## RH_9 -0.67088638  0.40633864  0.14033448  0.13526355  0.237862034 -0.03899100
## RH_10 -0.21282189 -0.30137196 -0.18458694 -0.55364752  0.363134774  0.42626576
## RH_11 -0.07643766  0.41032125 -0.28342113  0.24444158  0.039336194 -0.75902571
## RH_12  0.64325590  0.19044110 -0.21975096  0.06071786  0.619726462  0.06498233
## RH_13  0.21798586 -0.19615992  0.76788389  0.40875032  0.238711523  0.11023355
## RH_14  0.01809994 -0.23469219  0.80072702  0.30237281  0.076254577 -0.06686807
## RH_15 -0.10102305 -0.04451304  0.19453606 -0.33874643  0.687721548 -0.30741848
## RH_16 -0.20644844 -0.63189077 -0.23757449  0.53590502  0.057669955  0.12015151
```

```
#correlaciones variable factor
acp3$var$cor
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5      Dim.6
## RH_1 -0.35693798  0.70877743 -0.03696321  0.29065674  0.001408176  0.41343738
## RH_2  0.81930164  0.19450143 -0.10637763  0.37891761  0.192633367  0.05114370
## RH_5  0.90417056  0.20834627 -0.27356525 -0.04550233  0.012177864  0.06451571
## RH_6  0.20854441  0.30278075  0.62998230 -0.55512354 -0.174660976 -0.15421996
## RH_7 -0.51603493  0.71791876  0.10571827  0.09082143  0.134489129  0.25757944
## RH_8  0.79360603  0.30489947  0.26180205 -0.08636297 -0.243592220  0.18660305
## RH_9 -0.67088638  0.40633864  0.14033448  0.13526355  0.237862034 -0.03899100
## RH_10 -0.21282189 -0.30137196 -0.18458694 -0.55364752  0.363134774  0.42626576
## RH_11 -0.07643766  0.41032125 -0.28342113  0.24444158  0.039336194 -0.75902571
```

```
## RH_12  0.64325590  0.19044110 -0.21975096  0.06071786  0.619726462  0.06498233
## RH_13  0.21798586 -0.19615992  0.76788389  0.40875032  0.238711523  0.11023355
## RH_14  0.01809994 -0.23469219  0.80072702  0.30237281  0.076254577 -0.06686807
## RH_15 -0.10102305 -0.04451304  0.19453606 -0.33874643  0.687721548 -0.30741848
## RH_16 -0.20644844 -0.63189077 -0.23757449  0.53590502  0.057669955  0.12015151
```

```
#basicamente estas covarianzas nos habla de como las variables
#se relacionan con los factores y en que medida los construye
```

```
#cosenos cuadrados de las variables
acp3$var$cos2
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5      Dim.6
## RH_1  0.1274047208 0.50236545 0.001366279 0.084481342 1.982960e-06 0.170930470
## RH_2  0.6712551732 0.03783081 0.011316201 0.143578559 3.710761e-02 0.002615678
## RH_5  0.8175244042 0.04340817 0.074837947 0.002070462 1.483004e-04 0.004162277
## RH_6  0.0434907701 0.09167619 0.396877693 0.308162144 3.050646e-02 0.023783796
## RH_7  0.2662920502 0.51540735 0.011176352 0.008248532 1.808733e-02 0.066347168
## RH_8  0.6298105273 0.09296368 0.068540314 0.007458562 5.933717e-02 0.034820698
## RH_9  0.4500885389 0.16511109 0.019693767 0.018296227 5.657835e-02 0.001520298
## RH_10 0.0452931572 0.09082506 0.034072337 0.306525573 1.318669e-01 0.181702494
## RH_11 0.0058427156 0.16836353 0.080327536 0.059751685 1.547336e-03 0.576120031
## RH_12 0.4137781496 0.03626781 0.048290484 0.003686659 3.840609e-01 0.004222703
## RH_13 0.0475178359 0.03847871 0.589645668 0.167076823 5.698319e-02 0.012151436
## RH_14 0.0003276077 0.05508042 0.641163760 0.091429319 5.814760e-03 0.004471339
## RH_15 0.0102056570 0.00198141 0.037844280 0.114749141 4.729609e-01 0.094506122
## RH_16 0.0426209586 0.39928594 0.056441641 0.287194189 3.325824e-03 0.014436386
```


```
var_contrib3 <- data.frame(acp3$var$contrib)

top5_vars3 <- rownames(var_contrib3)[order(var_contrib3$Dim.1 + var_contrib3$Dim.2, decreasing = TRUE)]
sup_vars3 <- rownames(acp3$quanti.sup$coord)
all_vars3 <- c(top5_vars3, sup_vars3)
```

Gràficos punto #3

```
# Gráfico de individuos
G31<-fviz_pca_ind(acp3,
  col.ind = "cos2", # calidad de representación
  gradient.cols = c("darkgreen", "#FC4E07"),
  repel = TRUE
)
G31
```





En el gráfico podemos observar que destacan 4 ciudades, San Andrés, Bogotá,D.C., Riohacha y Valledupar, lo que da a entender que la mayor parte de variabilidad de esas ciudades esta siendo explicada por las componentes 1 y 2 (Dim1 y Dim2), además también se puede ver por cuál de las dimensiones parecen ser mejor representadas, por ejemplo, Valledupar y Riohacha parecen estar mejor representados por la componente 1 que San Bogotá,D.C., la cual parece estar mejor respresenta por la componente 2

```
cos2_ind_3 <- as.data.frame(acp3$ind$cos2)
cos2_ind_3_dim1 <- cos2_ind_3 %>% select(Dim.1,Dim.2) %>% mutate(cos2_total = rowSums(across(everything)))
arrange(desc(cos2_total))
```

A continuación se podrán ver los valores de los primeros 3  $\cos^2$  totales más altos:

Ciudad	$\cos^2$ Dim.1	$\cos^2$ Dim.2	$\cos^2$ total
Riohacha	0.75	0.03	0.78
Bogotá, D.C.	0.21	0.45	0.66
San Andrés	0.10	0.45	0.55
Valledupar	0.48	0.05	0.53

Como se mencionó anteriormente hay ciudades que destacan por componentes.

```
# Crear data frame con la dimensión de mayor cos2 por ciudad
tabla_max_cos2_3 <- cos2_ind_3 %>%
  as.data.frame() %>%
  mutate(
    ciudad = rownames(.),
```

```

mejor_componente = colnames(cos2_ind_3)[max.col(., ties.method = "first")],
max_cos2 = apply(., 1, max)
) %>%
select(ciudad, mejor_componente, max_cos2)
tabla_max_cos2_3

```

```

##               ciudad mejor_componente max_cos2
## Armenia          Armenia          Dim.4 0.2951413
## Barranquilla     Barranquilla          Dim.2 0.1162845
## Bogotá, D.C.     Bogotá, D.C.          Dim.2 0.4555949
## Bucaramanga      Bucaramanga          Dim.1 0.3668279
## Cali             Cali             Dim.1 0.2093450
## Cartage          Cartage          Dim.4 0.4398617
## Cúcuta           Cúcuta          Dim.6 0.1725695
## Ibagué           Ibagué          Dim.6 0.2901214
## Manizales        Manizales          Dim.1 0.4275987
## Medellín         Medellín          Dim.2 0.5261027
## Montería         Montería          Dim.1 0.4293558
## Neiva            Neiva            Dim.3 0.1613908
## Pasto            Pasto            Dim.6 0.4667174
## Pereira          Pereira          Dim.5 0.2756790
## Popayán          Popayán          Dim.1 0.3276161
## Riohacha         Riohacha          Dim.1 0.7524178
## San Arés         San Arés          Dim.2 0.4532104
## Santa Marta      Santa Marta          Dim.3 0.2679472
## Sincelejo        Sincelejo          Dim.5 0.5422884
## Tunja            Tunja            Dim.4 0.1950723
## Valledupar       Valledupar          Dim.1 0.4813210
## Villavicencio    Villavicencio      Dim.3 0.6446866

```

A continuación una tabla que dice cuantas veces la componente represento mejor al individuo, es decir la componente que tenía el  $\cos^2$  más alto entre todas las componentes.

```

tabla_max_cos2_3 %>% group_by(mejor_componente) %>% summarise(conteo=n()) %>% arrange(desc(conteo))

```

```

## # A tibble: 6 x 2
##   mejor_componente conteo
##   <chr>           <int>
## 1 Dim.1             7
## 2 Dim.2             4
## 3 Dim.3             3
## 4 Dim.4             3
## 5 Dim.6             3
## 6 Dim.5             2

```


Mejor componente	Conteo
Dim.1	7
Dim.2	4
Dim.3	3
Dim.4	3

Mejor componente	Conteo
Dim.5	2
Dim.6	3

Podemos ver que la componente 1 que explica aproximadamente el 25.5% de variabilidad de la población es la misma que logra representar mejor a 7 ciudades de 22 en total. Podemos ver que en los siguientes componentes va disminuyendo la cantidad de individuos que son mejor representados dentro de estos a comparación de los demás, aunque podemos ver que a pesar de que el componente 6 explica menos variabilidad de la población que el componente 5, logra explicar y representar más individuos que este.

```
G32<-fviz_pca_var(acp3,
  col.var = 'red',
  alpha.var = 0.5,
  repel = TRUE,
  col.quanti.sup = 'darkgrey',
  select.var = list(name =c(all_vars3)),
  title = 'Variables y suplementarias'
)
```

G32




```
G33<-fviz_pca_biplot(acp3,
  col.ind = "cos2",
  gradient.cols = c("darkgreen", "red"),
```

```

col.var = "darkblue",
repel = T,
col.quanti.sup = 'darkgrey',
select.var = list(name = c(all_vars3)),
geom = "text",
title = 'Biplot'
)
G33

```



Para este punto destacan nuevamente tres ciudades por su ubicación alejada del origen: Bogotá (3), San Andrés (17) y Riohacha (16).

San Andrés (17) se ubica en el tercer cuadrante con valores negativos en ambas dimensiones. Esta posición sugiere un bajo desempeño general, especialmente en infraestructura digital (INFR\_38, internet) y telecomunicaciones. Esto es coherente con su geografía insular y limitada escala urbana.

Bogotá (3) se encuentra en el segundo cuadrante, fuertemente asociada a variables como RH\_7 (educación superior) y RH\_1 (población), reflejando su liderazgo en aspectos demográficos y educativos.

Riohacha (16) se sitúa en el cuadrante superior derecho, destacándose por su fuerte asociación con RH\_5 (analfabetismo) y RH\_2 (crecimiento poblacional), lo que sugiere desafíos importantes en términos de desarrollo humano, a pesar de un crecimiento demográfico activo.