

LABORATORIO_5

Sergio Alejandro Buitrago Melo María Alejandra Cabra Arias
María Paula Camargo Rincón Ana María Chacón Bello
Sergio Alejandro Gaona Díaz Juan Esteban García Mute

2025-05-14

Contents

1 Preparación del dataframe	2
2 Punto 1	2
3 Punto 2	3
4 Punto 3	7
4.1 PUNTO 4	9
5 — PASO 1: CARGA Y PREPARACIÓN DE DATOS —	9
5.1 2. Agrupación con Índice Carlinski-Harabasz	9
6 — PASO 2: AGRUPACIÓN CON ÍNDICE CARLINSKI-HARABASZ —	9
6.1 3. Agrupación con Índice de Hartigan	11
7 — PASO 3: AGRUPACIÓN CON ÍNDICE DE HARTIGAN —	11
7.1 4. Comparación de Agrupaciones y Conclusiones Finales	13
8 — PASO 4: COMPARACIÓN DE LAS AGRUPACIONES —	13
9 Punto 5	14
10 Punto 7	33
0.0.1 Laboratorio #6	

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.1.4      v readr      2.1.5
## v forcats    1.0.0      v stringr   1.5.1
## v ggplot2    3.5.2      v tibble    3.2.1
## v lubridate  1.9.4      v tidyr     1.3.1
## v purrr      1.0.4
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(fpc)
```

```
## Warning: package 'fpc' was built under R version 4.5.1
```

```
library(NbClust)
library(tibble)
library(ggplot2)
library(knitr)
library(kableExtra)
```

```
## Warning: package 'kableExtra' was built under R version 4.5.1
```

```
##
## Adjuntando el paquete: 'kableExtra'
##
## The following object is masked from 'package:dplyr':
##
##      group_rows
```

```
library(sqldf)
```

```
## Cargando paquete requerido: gsubfn
## Cargando paquete requerido: proto
## Cargando paquete requerido: RSQLite
```

```
library(FactoMineR)
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

1 Preparación del dataframe

```
### creación de los datasets a usar
webo<-read.csv("r14_Sci_Qs_Webometrics.csv",sep = ";",dec = ",")
df <- read.csv("r14_Sci_Qs_Webometrics.csv",sep = ";",dec = ",")
df <- na.omit(df)
```

```

df <- df %>%
  group_by(Pais) %>%
  summarise(
    Universidades = n(),
    across(where(is.numeric), ~ mean(. , na.rm = TRUE))
  )

df <- column_to_rownames(df, var = "Pais")
df <- df[, 16:23]
datos <- df

df <- scale(df)

```

2 Punto 1

```


# --- 1. Calinski-Harabasz ---
ch_runs <- kmeansruns(df, krange = 2:10, criterion = "ch", runs = 100)
bestK_ch <- 3
km_ch <- kmeans(df, centers = bestK_ch, nstart = 25)
means_ch <- aggregate(df, by = list(Cluster = km_ch$cluster), FUN = mean)
vars_ch <- aggregate(df, by = list(Cluster = km_ch$cluster), FUN = var)

ch_vals <- ch_runs$crit
ch_Ks <- seq_along(ch_vals) + 1

plot(ch_Ks, ch_vals, type = "b",
     xlab = "Número de grupos (K)",
     ylab = "Valor del índice CH",
     main = "K según Calinski-Harabasz")
text(ch_Ks, ch_vals, labels = ch_Ks, pos = 3, cex = 0.8)
abline(v = bestK_ch, lty = 2, col = "red")
legend("topright",
     legend = paste("Mejor K =", bestK_ch),
     bty = "n", text.col = "red")

```

K según Calinski–Harabasz



3 Punto 2


```
# --- 2. Hartigan ---
nb_h      <- NbClust(data      = df,
                    distance = "euclidean",
                    min.nc    = 2,
                    max.nc    = 10,
                    method    = "kmeans",
                    index      = "hartigan")

bestK_h    <- 4
km_h       <- kmeans(df, centers = bestK_h, nstart = 25)
means_h    <- aggregate(df, by = list(Cluster = km_h$cluster), FUN = mean)
vars_h     <- aggregate(df, by = list(Cluster = km_h$cluster), FUN = var)

hart_vals  <- nb_h$All.index
hart_Ks    <- as.integer(names(hart_vals))

plot(hart_Ks, hart_vals, type = "b",
     xlab = "Número de grupos (K)",
     ylab = "Valor del índice Hartigan",
     main = "K según Hartigan")
text(hart_Ks, hart_vals, labels = hart_Ks, pos = 3, cex = 0.8)
```

```
abline(v = bestK_h, lty = 2, col = "red")
legend("topright",
      legend = paste("Mejor K =", bestK_h),
      bty = "n", text.col = "red")
```



TABLAS

```
# 3.1. Tabla de asignación de universidades a grupos (CH)
tabla_ch <- tibble(
  Universidad = rownames(df),
  Grupo      = km_ch$cluster
) %>%
  arrange(Grupo)
tabla_ch
```

```
## # A tibble: 12 x 2
##   Universidad Grupo
##   <chr>      <int>
## 1 CRI         1
## 2 PER         1
## 3 PRI         1
## 4 PY          1
## 5 URY         1
## 6 ECU         2
## 7 ARG         3
## 8 BRA         3
```

```
## 9 CHL 3
## 10 COL 3
## 11 MEX 3
## 12 VEN 3
```

3.2. Tabla de promedios por grupo (CH)

```
promedios_ch <- means_ch %>%
  rename(Grupo = Cluster)
promedios_ch
```

```
## Grupo SC.Productividad SC.Colaboracion.Interciol SC.Impacto.normalizado
## 1 1 -0.1276140 0.6725482 0.4901868
## 2 2 -1.0051672 1.7104418 1.9789604
## 3 3 0.2738729 -0.8455305 -0.7383157
## SC.Publicaciones.de.alta.calidad SC.Indice.de.especializacion
## 1 0.3093137 0.07751857
## 2 2.0634340 2.33164361
## 3 -0.6016671 -0.45320607
## SC.Indice.de.excelencia SC.Liderazgo.cientifico SC.Excelencia.con.liderazgo
## 1 0.3180748 -0.02218799 0.4366322
## 2 2.4212073 -2.76188450 -1.4126809
## 3 -0.6685969 0.47880407 -0.1284134
```

3.3. Tabla de asignación de universidades a grupos (Hartigan)

```
tabla_h <- tibble(
  Universidad = rownames(df),
  Grupo = km_h$cluster
) %>%
  arrange(Grupo)
tabla_h
```

```
## # A tibble: 12 x 2
## Universidad Grupo
## <chr> <int>
## 1 ARG 1
## 2 BRA 1
## 3 CHL 1
## 4 COL 1
## 5 MEX 1
## 6 VEN 1
## 7 CRI 2
## 8 PER 2
## 9 PY 2
## 10 PRI 3
## 11 URY 3
## 12 ECU 4
```

3.4. Tabla de promedios por grupo (Hartigan)

```
promedios_h <- means_h %>%
  rename(Grupo = Cluster)

knitr::kable(tabla_ch,
```

```
caption = "Asignación de universidades a grupos (Calinski-Harabasz)",
col.names = c("Universidad", "Grupo")) %>%
kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover"))
```

Table 1: Asignación de universidades a grupos (Calinski-Harabasz)

Universidad	Grupo
CRI	1
PER	1
PRI	1
PY	1
URY	1
ECU	2
ARG	3
BRA	3
CHL	3
COL	3
MEX	3
VEN	3

```
# 3.2. Promedios CH
knitr::kable(promedios_ch,
caption = "Promedios por grupo (Calinski-Harabasz)" %>%
kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 2: Promedios por grupo (C

Grupo	SC.Productividad	SC.Colaboracion.Interciol	SC.Impacto.normalizado	SC.Publicaciones.de.alta.calidad	SC
1	-0.1276140	0.6725482	0.4901868	0.3093137	
2	-1.0051672	1.7104418	1.9789604	2.0634340	
3	0.2738729	-0.8455305	-0.7383157	-0.6016671	

```
# 3.3. Tabla de asignación Hartigan
knitr::kable(tabla_h,
caption = "Asignación de universidades a grupos (Hartigan)",
col.names = c("Universidad", "Grupo")) %>%
kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover"))
```

Table 3: Asignación de universidades a grupos (Hartigan)

Universidad	Grupo
ARG	1
BRA	1
CHL	1
COL	1
MEX	1

VEN	1
CRI	2
PER	2
PY	2
PRI	3
URY	3
ECU	4

```
# 3.4. Promedios Hartigan
knitr::kable(promedios_h,
              caption = "Promedios por grupo (Hartigan)" %>%
              kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 4: Promedios por grupo

Grupo	SC.Productividad	SC.Colaboracion.Interciol	SC.Impacto.normalizado	SC.Publicaciones.de.alta.calidad	SC
1	0.2738729	-0.8455305	-0.7383157	-0.6016671	
2	-0.7997796	0.7981892	0.4220163	-0.0242514	
3	0.8806344	0.4840867	0.5924425	0.8096614	
4	-1.0051672	1.7104418	1.9789604	2.0634340	

4 Punto 3

```
#Tabla de promedios generales de los paises
prom_pais <- data.frame(País = rownames(datos),
                       Promedios = rowMeans(datos, na.rm = TRUE))
prom_pais <- prom_pais[order(-prom_pais$Promedios), ]

knitr::kable(prom_pais, row.names = FALSE,
              caption = "Promedios generales" %>%
              kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 5: Promedios generales

País	Promedios
BRA	921.32371
PRI	629.06875
URY	465.40000
MEX	377.26428
ARG	337.02192
CHL	249.22744
VEN	219.91900
COL	213.94313
CRI	201.97000
PER	102.06094
ECU	68.02563


```
#Tabla de objetos que han cambiado de grupo en los dos indicadores
tabla_comp <- data.frame(
  ID = rownames(datos),
  Grupo_CH = km_ch$cluster,
  Grupo_Hartigan = km_h$cluster
)

tabla_comp <- tabla_comp[order(tabla_comp$Grupo_CH), ]

knitr::kable(tabla_comp,
  caption = "Comparació de grupos dados en CH y Hartigan") %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 6: Comparació de grupos dados en CH y Hartigan

	ID	Grupo_CH	Grupo_Hartigan
CRI	CRI	1	2
PER	PER	1	2
PRI	PRI	1	3
PY	PY	1	2
URY	URY	1	3
ECU	ECU	2	4
ARG	ARG	3	1
BRA	BRA	3	1
CHL	CHL	3	1
COL	COL	3	1
MEX	MEX	3	1
VEN	VEN	3	1

#Interpretación En la tabla podemos observar que para el grupo 1 del indicador de Calinski–Harabasz todos los países pasaron a pertenecientes al grupo 4 en el indicador de Hartigan, algo que los caracteriza es que Argentina, Brasil, Chile, Colombia, Cuba, Mexico y Venezuela son los países que tienen los promedios generales mas altos de los 15 países, es decir, son los países que mejor les fue en general en los indicadores del Scimago; por lo que podemos decir que ambos indicadores distinguen esta característica en los objetos. También se puede ver que los países de Costa Rica, Panamá, Perú y Paraguay pasaron del grupo 2 al 3 en el indicador de HartiganPor. Por último los países de Puerto Rico y Uruguay pasaron de estar en grupo 3 con respecto a Calinski–Harabasz al grupo 1 con el indicador de Hartigan.

4.1 PUNTO 4

De el conjunto de datos r14_Sci_Qs_Webometrics.csv, seleccionamos las columnas correspondientes a los indicadores de QS, y agregar los datos a nivel de país calculando el promedio de cada indicador. Los valores faltantes (NA) se imputan con la media de su respectiva columna para poder aplicar el algoritmo K-medias.

5 — PASO 1: CARGA Y PREPARACIÓN DE DATOS —

```
webo<-read.csv("r14_Sci_Qs_Webometrics.csv",sep = ";",dec = ",")
datos_uni <- webo
# Seleccionar columnas de QS y forzar conversión a numérico
qs_cols <- colnames(datos_uni)[startsWith(colnames(datos_uni), "QS.")]
datos_qs <- datos_uni %>%
  select(Pais, all_of(qs_cols)) %>%
  mutate(across(all_of(qs_cols), as.numeric))

# Agrupar por país y calcular promedios
promedios_pais_qs <- datos_qs %>%
  group_by(Pais) %>%
  summarise(across(everything(), ~mean(.x, na.rm = TRUE)), .groups = 'drop')

# Preparar datos para clustering, extrayendo nombres
países_nombres <- promedios_pais_qs$Pais
datos_cluster_pre <- promedios_pais_qs %>% select(-Pais)

# Imputar NAs usando dplyr
datos_cluster <- datos_cluster_pre %>%
  mutate(across(everything(), ~ifelse(is.na(.), mean(., na.rm = TRUE), .)))

# Escalar los datos es crucial para K-medias
datos_escalados <- scale(datos_cluster)
rownames(datos_escalados) <- países_nombres

cat("Datos listos y escalados para el clustering.")
```

```
## Datos listos y escalados para el clustering.
```

5.1 2. Agrupación con Índice Carlinski-Harabasz

Se utiliza el índice de Carlinski-Harabasz (CH) para determinar el número óptimo de clústeres. Este índice evalúa la calidad de la agrupación basándose en la relación entre la varianza inter-clúster y la varianza intra-clúster.

6 — PASO 2: AGRUPACIÓN CON ÍNDICE CARLINSKI-HARABASZ —

```
cat("--- Determinando el número de clústeres con Carlinski-Harabasz ---\n")
```

```
## --- Determinando el número de clústeres con Carlinski-Harabasz ---
```

```
set.seed(123)
nc_ch <- NbClust(datos_escalados, min.nc = 2, max.nc = 10, method = "kmeans", index = "ch")
```

```
k_ch <- nc_ch$Best.nc[1]
cat(paste("\nEl número óptimo de clústeres según Carlinski-Harabasz es:", k_ch, "\n"))
```

```
##
## El número óptimo de clústeres según Carlinski-Harabasz es: 5
```

```
# Realizar el clustering K-medias
kmeans_ch <- kmeans(datos_escalados, centers = k_ch, nstart = 25)
promedios_pais_qs$cluster_ch <- kmeans_ch$cluster
```

```
# Tipificar los clústeres
cat("\n--- Perfil de los clústeres (Carlinski-Harabasz) ---\n")
```

```
##
## --- Perfil de los clústeres (Carlinski-Harabasz) ---
```

```
perfil_ch <- promedios_pais_qs %>%
  select(-Pais) %>%
  group_by(cluster_ch) %>%
  summarise(across(everything(), ~mean(.x, na.rm = TRUE)), .groups = 'drop') %>%
  mutate(Num_Paises = as.integer(table(kmeans_ch$cluster)))
kable(perfil_ch, caption = "Perfil de Clústeres (Medias) - Carlinski-Harabasz", digits = 2)
```

Table 7: Perfil de Clústeres (Medias) - Carlinski-Harabasz

cluster	QS_Ran	QS_P	QS_Sing	QS_Reputa	QS_Aceptancia	QS_Estabilidad	QS_PropAfect	QS_Sipar	QS_Dificult	QS_Impact	Num_Paises
1	93.50	50.54		55.64	62.27	71.51	4.26	94.40	18.53	59.21	3
2	38.50	71.25		87.30	82.70	54.70	11.85	90.90	15.50	91.60	1
3	62.94	63.16		49.97	46.15	54.16	62.10	73.70	96.18	89.70	2
4	106.33	47.15		45.87	56.63	18.15	10.85	90.62	32.77	81.15	2
5	76.69	58.61		69.26	65.01	42.69	31.20	52.47	44.67	79.75	7

```
cat("\n--- Países por Clúster (Carlinski-Harabasz) ---\n")
```

```
##
## --- Países por Clúster (Carlinski-Harabasz) ---
```

```
split(paises_nombres, kmeans_ch$cluster)
```

```
## $`1`
## [1] "PAN" "PY" "URY"
##
## $`2`
## [1] "CRI"
##
## $`3`
## [1] "BRA" "PRI"
##
## $`4`
```

```
## [1] "BOL" "ECU"
##
## $`5`
## [1] "ARG" "CHL" "COL" "CUB" "MEX" "PER" "VEN"
```

6.0.1 Análisis del Resultado (Carlinski-Harabasz)

El índice de Carlinski-Harabasz sugiere que la estructura óptima de los datos consiste en 5 *clústeres*. A continuación se describe el perfil de cada uno:

- *Clúster 1 (Especialistas en Impacto de Citas): Agrupa a **Panamá, Paraguay y Uruguay*. Este grupo destaca por tener el mayor impacto de citas por artículo (QS.Citas.por.articulo = 94.40), pero muestra debilidades en producción científica y formación doctoral.
- *Clúster 2 (Líder Indiscutible): Compuesto únicamente por **Costa Rica*. Representa el rendimiento de élite, liderando en puntuación general (71.25) y reputación académica (87.30), lo que lo aísla del resto.
- *Clúster 3 (Potencias en Investigación): Incluye a **Brasil y Puerto Rico*. Su principal fortaleza es la alta producción de artículos (62.10) y el altísimo porcentaje de docentes con doctorado (96.18).
- *Clúster 4 (Sistemas en Desarrollo): Formado por **Bolivia y Ecuador*. Este grupo presenta los promedios más bajos en la mayoría de los indicadores de QS, especialmente en reputación y puntuación general.
- *Clúster 5 (Núcleo Consolidado): Es el grupo más grande, con **Argentina, Chile, Colombia, Cuba, México, Perú y Venezuela*. Se caracteriza por un rendimiento balanceado y sólido en todos los indicadores, conformando el núcleo competitivo de la región.

6.1 3. Agrupación con Índice de Hartigan

Como método de validación, se repite el proceso utilizando el índice de Hartigan, una regla heurística que busca un “codo” o punto de inflexión en la mejora de la homogeneidad de los clústeres.

7 — PASO 3: AGRUPACIÓN CON ÍNDICE DE HARTIGAN —

```
cat("\n\n--- Determinando el número de clústeres con Hartigan ---\n")
```

```
##
##
## --- Determinando el número de clústeres con Hartigan ---
```

```
set.seed(123)
nc_hartigan <- NbClust(datos_escalados, min.nc = 2, max.nc = 10, method = "kmeans", index = "hartigan")

k_hartigan <- nc_hartigan$Best.nc[1]
cat(paste("\nEl número óptimo de clústeres según Hartigan es:", k_hartigan, "\n"))
```

```
##
## El número óptimo de clústeres según Hartigan es: 5
```

```
kmeans_hartigan <- kmeans(datos_escalados, centers = k_hartigan, nstart = 25)
promedios_pais_qs$cluster_hartigan <- kmeans_hartigan$cluster

cat("\n--- Perfil de los clústeres (Hartigan) ---\n")
```

cluster_	QSTRank	QSP	QSR	QSR	QSR	QSR	QSR	QSR	QSR	QSR	QSR
	QSTRank	QSP	QSR	QSR	QSR	QSR	QSR	QSR	QSR	QSR	QSR
1	93.50	50.54	55.64	62.27	71.51	4.26	94.40	18.53	59.21	3	
2	38.50	71.25	87.30	82.70	54.70	11.85	90.90	15.50	91.60	1	
3	62.94	63.16	49.97	46.15	54.16	62.10	73.70	96.18	89.70	2	
4	106.33	47.15	45.87	56.63	18.15	10.85	90.62	32.77	81.15	2	
5	76.69	58.61	69.26	65.01	42.69	31.20	52.47	44.67	79.75	7	

```
cat("\n--- Países por Clúster (Hartigan) ---\n")
```

7.1 4. Comparación de Agrupaciones y Conclusiones Finales

Para formalizar la comparación, se construye una tabla de contingencia que cruza las asignaciones de ambos métodos.

8 — PASO 4: COMPARACIÓN DE LAS AGRUPACIONES —

```
cat("\n\n--- Comparación de las dos agrupaciones ---\n")

##
##
## --- Comparación de las dos agrupaciones ---

comparacion <- table(CH_Cluster = promedios_pais_qs$cluster_ch,
                    Hartigan_Cluster = promedios_pais_qs$cluster_hartigan)
kable(comparacion, caption = "Tabla de Contingencia: Carlinski-Harabasz vs. Hartigan")
```

Table 9: Tabla de Contingencia: Carlinski-Harabasz vs. Hartigan

	1	2	3	4	5
3	0	0	0	0	0
0	1	0	0	0	0
0	0	2	0	0	0
0	0	0	2	0	0
0	0	0	0	7	

```
cat("\nAsignación de cada país en ambas agrupaciones:\n")

##
## Asignación de cada país en ambas agrupaciones:

kable(promedios_pais_qs[, c("Pais", "cluster_ch", "cluster_hartigan")],
      row.names = FALSE,
      caption="Asignación de clúster por país para ambos métodos")
```

Table 10: Asignación de clúster por país para ambos métodos

Pais	cluster_ch	cluster_hartigan
ARG	5	5
BOL	4	4
BRA	3	3
CHL	5	5
COL	5	5
CRI	2	2
CUB	5	5
ECU	4	4

Pais	cluster_ch	cluster_hartigan
MEX	5	5
PAN	1	1
PER	5	5
PRI	3	3
PY	1	1
URY	1	1
VEN	5	5

8.0.1 Conclusión

El análisis nos revela que: *ambos índices de validación (Carlinski-Harabasz y Hartigan) coinciden en que la estructura más apropiada para los datos es una partición de 5 clústeres, y además, ambos métodos generan exactamente la misma agrupación de países.*

La tabla de contingencia es una *matriz diagonal perfecta*, lo que indica una concordancia del 100% entre los dos resultados. Esta robustez nos permite concluir con alta confianza que, según los indicadores de QS, el panorama universitario en Latinoamérica se segmenta en cinco perfiles bien definidos:

1. *Líder de Élite (CRI)*: Destacado por su reputación y puntuación general.
2. *Potencias de Investigación (BRA, PRI)*: Fuertes en producción científica y formación doctoral.
3. *Núcleo Competitivo (ARG, CHL, COL, etc.)*: Grupo grande con un rendimiento sólido y balanceado.
4. *Especialistas en Impacto (PAN, PY, URY)*: Sobresalen en citas por artículo a pesar de una menor producción.
5. *Sistemas en Desarrollo (BOL, ECU)*: Con los mayores desafíos en las métricas académicas tradicionales de QS.

Este análisis va más allá de un simple ranking y ofrece una visión más clara de las fortalezas y debilidades de los sistemas de educación superior en la región.

9 Punto 5


```
webo1<-webo[,c(2,9:15)] %>% na.omit() #hay que omitir los na


# Reemplaza puntos por guiones bajos
names(webo1) <- gsub("\\.", "_", names(webo1))

# Calcular promedios por país
mediaspais <- webo1 %>%
  group_by(Pais) %>%
  summarise(across(everything(), mean, .names = "media_{.col}"))

#View(mediaspais)
# Colocar nombres de país como nombres de fila
mediaspais <- column_to_rownames(mediaspais,var="Pais")
View(mediaspais)

res.PCA<-PCA(mediaspais)
```







```
eig <- round(res.PCA$eig, 2)
eig
```

##	eigenvalue	percentage of variance	cumulative percentage of variance
## comp 1	3.00	42.84	42.84
## comp 2	1.72	24.61	67.45
## comp 3	0.98	13.95	81.41
## comp 4	0.60	8.62	90.03
## comp 5	0.42	5.97	96.00
## comp 6	0.23	3.35	99.35
## comp 7	0.05	0.65	100.00

El presente análisis busca identificar agrupamientos de países latinoamericanos en función de los indicadores promedio de calidad universitaria provenientes de los rankings de QS. Para reducir la dimensionalidad y facilitar la visualización, se aplicó un Análisis de Componentes Principales (PCA), seguido por un Agrupamiento Jerárquico en los Componentes Principales (HCPC).


```
res.PCA2<-PCA(mediaspais) #cuantos factores se usan?
```






```
res.hcpc <- HCPC(
  res.PCA2,
  nb.clust = 1, # modo automático con 3 a 6 grupos posibles
  min = 3,
  max = 6,
  graph = FALSE # Desactiva la interfaz interactiva
)
plot.HCPC(res.hcpc, axes = c(1,3), choice = "tree", title = "Agrupamiento Jerárquico")
```

Agrupamiento Jerárquico



```
plot.HCPC(res.hcpc, axes = c(1,3), choice = "map")
```


Factor map




Podemos observar que el algoritmo ha identificado cuatro clústeres bien diferenciados. Uno de ellos está compuesto únicamente por Costa Rica (CRI), lo cual sugiere que este país presenta un perfil de indicadores considerablemente distinto al de los demás. Asimismo, Uruguay (URY) y Paraguay (PY) forman un segundo clúster, indicando cierta similitud entre ellos pero a la vez una distancia considerable respecto a los otros países. Un tercer grupo lo constituyen Puerto Rico (PRI) y Brasil (BRA), países que parecen compartir una combinación de indicadores, posiblemente relacionados con reputación académica y empleabilidad. Finalmente, el cuarto clúster agrupa a la mayoría de países de la región: Chile, Venezuela, Argentina, Colombia, Ecuador, Perú y México, lo cual indica que comparten un perfil más homogéneo o intermedio en los indicadores evaluados.

```
# Clustering jerárquico sobre los componentes principales
res.hcpc <- HCPC(res.PCA, nb.clust = -1, min = 3, max = 6)
```


Hierarchical Clustering



Hierarchical clustering on the factor map




Factor map



En este gráfico se muestra una versión tridimensional del dendrograma, proyectado sobre los dos primeros componentes principales (Dim 1 y Dim 2), con la altura del dendrograma como tercera dimensión. Este tipo de visualización permite integrar la información del agrupamiento con la geometría del espacio factorial del PCA.

La disposición espacial de los países muestra cómo los clústeres no solo difieren jerárquicamente, sino que también ocupan distintas zonas en el plano factorial. Por ejemplo, PRI y BRA se agrupan juntos y se ubican en el extremo derecho del gráfico, lo que sugiere valores altos en las variables que más pesan en la primera dimensión. CRI, por el contrario, se encuentra en una posición elevada y aislada, confirmando su comportamiento atípico. Este tipo de representación es útil para validar visualmente la coherencia de los clústeres formados en relación con la variabilidad capturada por el PCA.

```
# Mapa de factores con clusters
plot.HCPC(res.hcpc, axes = c(1, 3), choice = "map")
```





El gráfico de dimensiones 1 y 3 ofrece una perspectiva adicional del posicionamiento de los países. Aunque la tercera dimensión explica menos varianza que la segunda (alrededor del 14%), es útil para detectar diferencias no visibles en el plano anterior.

Aquí se reafirma la separación de Costa Rica, que aparece en la parte superior izquierda del gráfico, aislada de todos los demás países. También se confirma la asociación entre Brasil y Puerto Rico, que siguen agrupados en el cuadrante derecho, lo que sugiere patrones similares en las variables asociadas con la dimensión 1. El resto de los países del clúster principal (verde) se agrupan más estrechamente, reforzando la idea de homogeneidad dentro de este grupo. Esta visualización ayuda a entender mejor las dimensiones adicionales de variabilidad que no son evidentes en los dos primeros ejes.

```
fviz_cluster(res.hcpc, ellipse.type = "norm", ellipse.level = 0.9, ellipse.alpha = 0.3)
```

```
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
```



Este gráfico proyecta los países sobre el mismo plano factorial anterior (Dim 1 y 2), pero añade elipses de confianza alrededor de los clústeres, permitiendo evaluar la dispersión interna de cada grupo y su separación relativa.

Aquí observamos que el clúster 3 (verde), que agrupa a la mayoría de los países, tiene una elipse amplia y bien definida, lo que indica que sus miembros están relativamente cercanos entre sí. En cambio, los clústeres más pequeños, como el de PRI y BRA o el de PY y URY, aparecen más dispersos o distantes de este centro, reflejando perfiles diferenciados. Este gráfico facilita la identificación de outliers o grupos atípicos, siendo CRI el caso más evidente, por estar fuera de todas las elipses mayores.

#Conclusiones El análisis conjunto del PCA y el HCPC permite identificar cuatro grupos principales de países latinoamericanos según las características promedio de sus universidades:

Cluster 1 (Costa Rica): un perfil atípico, posiblemente con puntuaciones extremas en reputación y otros indicadores, como antes se había visto este país tiene un dato que parece erróneo.

Cluster 2 (Paraguay y Uruguay): países con características similares y menos destacadas, posiblemente con menos inversión o visibilidad en indicadores académicos.

Cluster 3 (Chile, México, Argentina, Colombia, Ecuador, Perú, Venezuela): grupo más grande y homogéneo, con valores intermedios y equilibrados en los distintos indicadores, países que ya de ante mano tienen características similares.

Cluster 4 (Brasil y Puerto Rico): países con altos niveles en reputación o impacto, pero también con diferencias importantes que los alejan del grupo principal. # Punto 6

```
webo2<-webo[,c(2,3,6,16:24)]
View(webo2)


medias_pais2 <- webo2 %>% group_by(Pais) %>% summarise(
```


```

"media de SC.Lac.Ranking"=mean(SC.Lac.Ranking),
"media de SC.Ibe.Ranking"=mean(SC.Ibe.Ranking),
"media de SC.Co.Ranking"=mean(SC.Co.Ranking),
"media de SC.Productividad"=mean(SC.Productividad),
"media de SC.Colaboracion.Interciol"=mean(SC.Colaboracion.Interciol),
"media de SC.Impacto.normalizado"=mean(SC.Impacto.normalizado),
"media de SC.Publicaciones.de.alta.calidad"=mean(SC.Publicaciones.de.alta.calidad),
"media de SC.Indice.de.especializacion"=mean(SC.Indice.de.especializacion),
"media de SC.Indice.de.excelencia"=mean(SC.Indice.de.excelencia),
"media de SC.Liderazgo.cientifico"=mean(SC.Liderazgo.cientifico),
"media de SC.Excelencia.con.liderazgo"=mean(SC.Excelencia.con.liderazgo)
)

medias_pais2 <- column_to_rownames(medias_pais2,var="Pais")
res.PCA2<-PCA(medias_pais2)

```







```
eig2 <- round(res.PCA2$eig, 2)
eig2
```

##	eigenvalue	percentage of variance	cumulative percentage of variance
## comp 1	4.88	44.40	44.40
## comp 2	2.77	25.16	69.56
## comp 3	1.48	13.43	82.99
## comp 4	0.78	7.12	90.11
## comp 5	0.39	3.57	93.68
## comp 6	0.28	2.52	96.20
## comp 7	0.21	1.92	98.12
## comp 8	0.11	0.99	99.11
## comp 9	0.08	0.75	99.87
## comp 10	0.01	0.13	100.00
## comp 11	0.00	0.00	100.00

```
res.PCA4<-PCA(medias_pais2, ncp = 2) # Para utilizar solamente los dos primeros factores
```






```
res.hcpc2 <- HCPC(
  res.PCA4,
  nb.clust = 1, # modo automático con 3 a 6 grupos posibles
  min = 3,
  max = 6,
  graph = FALSE # Desactiva la interfaz interactiva
)


plot.HCPC(res.hcpc2, axes = c(1,2), choice = "tree", title = "Agrupamiento Jerárquico")
```

Agrupamiento Jerárquico




```
plot.HCPC(res.hcpc2, axes = c(1,2), choice = "map")
```

Factor map



```
fviz_cluster(res.hcpc2, ellipse.type = "norm", ellipse.level = 0.9, ellipse.alpha = 0.3)
```

```
## Too few points to calculate an ellipse  
## Too few points to calculate an ellipse  
## Too few points to calculate an ellipse  
## Too few points to calculate an ellipse
```

Interpretación: Se usaron los indicadores de QS como:

- Reputación académica
- Reputación entre empleadores
- Citas por artículo
- Estudiantes por profesor
- Docentes con doctorado
- Impacto web

Se realizó un PCA para reducir dimensiones y un HCPC para agrupar los países.

Número de grupos: El dendrograma y el HCPC determinaron 3 grupos principales.

Descripción de los grupos: Grupo 1: Universidades altamente reconocidas Alta reputación académica y entre empleadores

Alto impacto web

Ejemplos: Brasil, México, Argentina (universidades líderes como USP, UNAM, UBA)

Grupo 2: Universidades con balance intermedio Buen nivel en varios indicadores, pero menor liderazgo en citas o publicaciones por docente

Ejemplos: Chile, Colombia, Perú

Grupo 3: Universidades con menor visibilidad QS Baja reputación internacional y menos citas por artículo

Ejemplos: Venezuela, Paraguay, Ecuador

10 Punto 7

Comparación entre Scimago y QS

Aspecto	Scimago	QS
Variables	Productividad científica, colaboración, impacto normalizado	Reputación, citas, impacto web
Número de grupos	3	3
Diferencias principales	Scimago mide producción científica objetiva	QS mide percepción y visibilidad
Coincidencia de grupos	Coinciden parcialmente en el grupo 1 y el grupo 3, pero el grupo 2 difiere	
Ejemplo de diferencia	Algunos países tienen buena producción científica (Scimago) pero baja reputación (QS), o viceversa	

10.0.1 Conclusión:

El análisis muestra que existen diferencias entre la percepción internacional (QS) y la producción científica real (Scimago).

Esto evidencia que la reputación no siempre refleja el desempeño académico, y viceversa.