

# LABORATORIO\_5

Sergio Alejandro Buitrago Melo  
María Paula Camargo Rincón  
Sergio Alejandro Gaona Díaz

María Alejandra Cabra Arias  
Ana María Chacón Bello  
Juan Esteban García Muete

2025-05-14

## Contents

|   |                           |    |
|---|---------------------------|----|
| 1 | Preparación del dataframe | 2  |
| 2 | Punto 1                   | 2  |
| 3 | Punto 2                   | 3  |
| 4 | Punto 3                   | 7  |
| 5 | Punto 5                   | 9  |
| 6 | Punto 7                   | 27 |

### 0.0.1 Laboratorio #6

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.1.4      v readr      2.1.5
## v forcats    1.0.0      v stringr   1.5.1
## v ggplot2    3.5.2      v tibble    3.2.1
## v lubridate  1.9.4      v tidyr     1.3.1
## v purrr      1.0.4
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
library(fpc)
```

```
## Warning: package 'fpc' was built under R version 4.5.1
```

```
library(NbClust)
library(tibble)
library(ggplot2)
library(knitr)
library(kableExtra)
```

```
## Warning: package 'kableExtra' was built under R version 4.5.1
```

```
##
## Adjuntando el paquete: 'kableExtra'
##
## The following object is masked from 'package:dplyr':
##
##     group_rows
```

```
library(sqldf)
```

```
## Cargando paquete requerido: gsubfn
## Cargando paquete requerido: proto
## Cargando paquete requerido: RSQLite
```

```
library(FactoMineR)
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

## 1 Preparación del dataframe

```
### creación de los datasets a usar
webo<-read.csv("r14_Sci_Qs_Webometrics.csv",sep = ";",dec = ",")
df <- read.csv("r14_Sci_Qs_Webometrics.csv",sep = ";",dec = ",")
df <- na.omit(df)

df <- df %>%
  group_by(Pais) %>%
  summarise(
    Universidades = n(),
    across(where(is.numeric), ~ mean(. , na.rm = TRUE))
  )

df <- column_to_rownames(df, var = "Pais")
df <- df[, 16:23]
datos <- df


df <- scale(df)
```

## 2 Punto 1

```
# --- 1. Calinski-Harabasz ---
ch_runs  <- kmeansruns(df, krange = 2:10, criterion = "ch", runs = 100)
bestK_ch <- 3
km_ch    <- kmeans(df, centers = bestK_ch, nstart = 25)
means_ch <- aggregate(df, by = list(Cluster = km_ch$cluster), FUN = mean)
vars_ch  <- aggregate(df, by = list(Cluster = km_ch$cluster), FUN = var)

ch_vals  <- ch_runs$crit
ch_Ks    <- seq_along(ch_vals) + 1

plot(ch_Ks, ch_vals, type = "b",
     xlab = "Número de grupos (K)",
     ylab = "Valor del índice CH",
     main = "K según Calinski-Harabasz")
text(ch_Ks, ch_vals, labels = ch_Ks, pos = 3, cex = 0.8)
abline(v = bestK_ch, lty = 2, col = "red")
legend("topright",
     legend = paste("Mejor K =", bestK_ch),
     bty = "n", text.col = "red")
```



### 3 Punto 2


```
# --- 2. Hartigan ---
nb_h      <- NbClust(data      = df,
                     distance = "euclidean",
                     min.nc   = 2,
                     max.nc   = 10,
                     method   = "kmeans",
                     index    = "hartigan")

bestK_h    <- 4
km_h       <- kmeans(df, centers = bestK_h, nstart = 25)
means_h    <- aggregate(df, by = list(Cluster = km_h$cluster), FUN = mean)
vars_h     <- aggregate(df, by = list(Cluster = km_h$cluster), FUN = var)

hart_vals  <- nb_h$All.index
hart_Ks    <- as.integer(names(hart_vals))

plot(hart_Ks, hart_vals, type = "b",
     xlab = "Número de grupos (K)",
     ylab = "Valor del índice Hartigan",
     main = "K según Hartigan")
text(hart_Ks, hart_vals, labels = hart_Ks, pos = 3, cex = 0.8)
abline(v = bestK_h, lty = 2, col = "red")
legend("topright",
     legend = paste("Mejor K =", bestK_h),
     bty = "n", text.col = "red")
```

## K según Hartigan



## TABLAS

# 3.1. Tabla de asignación de universidades a grupos (CH)

```
tabla_ch <- tibble(
  Universidad = rownames(df),
  Grupo       = km_ch$cluster
) %>%
  arrange(Grupo)
tabla_ch
```

```
## # A tibble: 12 x 2
##   Universidad Grupo
##   <chr>      <int>
## 1 ARG         1
## 2 BRA         1
## 3 CHL         1
## 4 COL         1
## 5 MEX         1
## 6 VEN         1
## 7 CRI         2
## 8 PER         2
## 9 PRI         2
## 10 PY         2
## 11 URY         2
## 12 ECU         3
```

```
# 3.2. Tabla de promedios por grupo (CH)
```

```
promedios_ch <- means_ch %>%
  rename(Grupo = Cluster)
promedios_ch
```

```
##   Grupo SC.Productividad SC.Colaboracion.Interciol SC.Impacto.normalizado
## 1     1         0.2738729          -0.8455305          -0.7383157
## 2     2        -0.1276140           0.6725482           0.4901868
## 3     3        -1.0051672           1.7104418           1.9789604
##   SC.Publicaciones.de.alta.calidad SC.Indice.de.especializacion
## 1                        -0.6016671                -0.45320607
## 2                        0.3093137                 0.07751857
## 3                        2.0634340                 2.33164361
##   SC.Indice.de.excelencia SC.Liderazgo.cientifico SC.Excelencia.con.liderazgo
## 1                -0.6685969                0.47880407          -0.1284134
## 2                0.3180748               -0.02218799           0.4366322
## 3                2.4212073               -2.76188450          -1.4126809
```

```
# 3.3. Tabla de asignación de universidades a grupos (Hartigan)
```

```
tabla_h <- tibble(
  Universidad = rownames(df),
  Grupo      = km_h$cluster
) %>%
  arrange(Grupo)
tabla_h
```

```
## # A tibble: 12 x 2
##   Universidad Grupo
##   <chr>      <int>
## 1 ARG         1
## 2 BRA         1
## 3 CHL         1
## 4 COL         1
## 5 MEX         1
## 6 VEN         1
## 7 CRI         2
## 8 PER         2
## 9 PY          2
## 10 PRI        3
## 11 URY        3
## 12 ECU        4
```

```
# 3.4. Tabla de promedios por grupo (Hartigan)
```

```
promedios_h <- means_h %>%
  rename(Grupo = Cluster)

knitr::kable(tabla_h,
  caption = "Asignación de universidades a grupos (Calinski-Harabasz)",
  col.names = c("Universidad", "Grupo")) %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover"))
```

Table 1: Asignación de universidades a grupos (Calinski–Harabasz)

| Universidad | Grupo |
|-------------|-------|
| ARG         | 1     |
| BRA         | 1     |
| CHL         | 1     |
| COL         | 1     |
| MEX         | 1     |
| VEN         | 1     |
| CRI         | 2     |
| PER         | 2     |
| PRI         | 2     |
| PY          | 2     |
| URY         | 2     |
| ECU         | 3     |

```
# 3.2. Promedios CH
knitr::kable(promedios_ch,
              caption = "Promedios por grupo (Calinski-Harabasz)" %>%
              kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 2: Promedios por grupo (C

| Grupo | SC.Productividad | SC.Colaboracion.Interciol | SC.Impacto.normalizado | SC.Publicaciones.de.alta.calidad | SC |
|-------|------------------|---------------------------|------------------------|----------------------------------|----|
| 1     | 0.2738729        | -0.8455305                | -0.7383157             | -0.6016671                       |    |
| 2     | -0.1276140       | 0.6725482                 | 0.4901868              | 0.3093137                        |    |
| 3     | -1.0051672       | 1.7104418                 | 1.9789604              | 2.0634340                        |    |

```
# 3.3. Tabla de asignación Hartigan
knitr::kable(tabla_h,
              caption = "Asignación de universidades a grupos (Hartigan)",
              col.names = c("Universidad", "Grupo")) %>%
              kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover"))
```

Table 3: Asignación de universidades a grupos (Hartigan)

| Universidad | Grupo |
|-------------|-------|
| ARG         | 1     |
| BRA         | 1     |
| CHL         | 1     |
| COL         | 1     |
| MEX         | 1     |
| VEN         | 1     |
| CRI         | 2     |
| PER         | 2     |
| PY          | 2     |
| PRI         | 3     |

|     |   |
|-----|---|
| URY | 3 |
| ECU | 4 |

```
# 3.4. Promedios Hartigan
knitr::kable(promedios_h,
              caption = "Promedios por grupo (Hartigan)") %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 4: Promedios por grupo

| Grupo | SC.Productividad | SC.Colaboracion.Interciol | SC.Impacto.normalizado | SC.Publicaciones.de.alta.calidad | SC.Publicaciones.de.alta.calidad |
|-------|------------------|---------------------------|------------------------|----------------------------------|----------------------------------|
| 1     | 0.2738729        | -0.8455305                | -0.7383157             | -0.6016671                       | -0.6016671                       |
| 2     | -0.7997796       | 0.7981892                 | 0.4220163              | -0.0242514                       | -0.0242514                       |
| 3     | 0.8806344        | 0.4840867                 | 0.5924425              | 0.8096614                        | 0.8096614                        |
| 4     | -1.0051672       | 1.7104418                 | 1.9789604              | 2.0634340                        | 2.0634340                        |

## 4 Punto 3

```
#Tabla de promedios generales de los paises
prom_pais <- data.frame(País = rownames(datos),
                       Promedios = rowMeans(datos, na.rm = TRUE))
prom_pais <- prom_pais[order(-prom_pais$Promedios), ]

knitr::kable(prom_pais, row.names = FALSE,
              caption = "Promedios generales") %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))
```

Table 5: Promedios generales

| País | Promedios |
|------|-----------|
| BRA  | 921.32371 |
| PRI  | 629.06875 |
| URY  | 465.40000 |
| MEX  | 377.26428 |
| ARG  | 337.02192 |
| CHL  | 249.22744 |
| VEN  | 219.91900 |
| COL  | 213.94313 |
| CRI  | 201.97000 |
| PER  | 102.06094 |
| ECU  | 68.02563  |
| PY   | 47.01500  |

```
#Tabla de objetos que han cambiado de grupo en los dos indicadores
tabla_comp <- data.frame(
  ID = rownames(datos),
```



```

Grupo_CH = km_ch$cluster,
Grupo_Hartigan = km_h$cluster
)

tabla_comp <- tabla_comp[order(tabla_comp$Grupo_CH), ]

knitr::kable(tabla_comp,
              caption = "Comparació de grupos dados en CH y Hartigan") %>%
  kable_styling(full_width = FALSE, bootstrap_options = c("condensed", "responsive"))

```

Table 6: Comparació de grupos dados en CH y Hartigan

|     | ID  | Grupo_CH | Grupo_Hartigan |
|-----|-----|----------|----------------|
| ARG | ARG | 1        | 1              |
| BRA | BRA | 1        | 1              |
| CHL | CHL | 1        | 1              |
| COL | COL | 1        | 1              |
| MEX | MEX | 1        | 1              |
| VEN | VEN | 1        | 1              |
| CRI | CRI | 2        | 2              |
| PER | PER | 2        | 2              |
| PRI | PRI | 2        | 3              |
| PY  | PY  | 2        | 2              |
| URY | URY | 2        | 3              |
| ECU | ECU | 3        | 4              |

#Interpretación En la tabla podemos observar que para el grupo 1 del indicador de Calinski-Harabasz todos los países pasaron a pertenecientes al grupo 4 en el indicador de Hartigan, algo que los caracteriza es que Argentina, Brasil, Chile, Colombia, Cuba, Mexico y Venezuela son los países que tienen los promedios generales mas altos de los 15 países, es decir, son los países que mejor les fue en general en los indicadores del Scimago; por lo que podemos decir que ambos indicadores distinguen esta característica en los objetos. También se puede ver que los países de Costa Rica, Panamá, Perú y Paraguay pasaron del grupo 2 al 3 en el indicador de HartiganPor. Por último los países de Puerto Rico y Uruguay pasaron de estar en grupo 3 con respecto a Calinski-Harabasz al grupo 1 con el indicador de Hartigan.

## 5 Punto 5

```

webo1<-webo[,c(2,9:15)] %>% na.omit() #hay que omitir los na

# Reemplaza puntos por guiones bajos
names(webo1) <- gsub("\\.", "_", names(webo1))


# Calcular promedios por país
mediaspais <- webo1 %>%
  group_by(Pais) %>%
  summarise(across(everything(), mean, .names = "media_{.col}"))


#View(mediaspais)

```

```
# Colocar nombres de país como nombres de fila
mediaspais <- column_to_rownames(mediaspais,var="País")
View(mediaspais)

res.PCA<-PCA(mediaspais)
```







```
eig <- round(res.PCA$eig, 2)
eig
```

| ##        | eigenvalue | percentage of variance | cumulative percentage of variance |
|-----------|------------|------------------------|-----------------------------------|
| ## comp 1 | 3.00       | 42.84                  | 42.84                             |
| ## comp 2 | 1.72       | 24.61                  | 67.45                             |
| ## comp 3 | 0.98       | 13.95                  | 81.41                             |
| ## comp 4 | 0.60       | 8.62                   | 90.03                             |
| ## comp 5 | 0.42       | 5.97                   | 96.00                             |
| ## comp 6 | 0.23       | 3.35                   | 99.35                             |
| ## comp 7 | 0.05       | 0.65                   | 100.00                            |

El presente análisis busca identificar agrupamientos de países latinoamericanos en función de los indicadores promedio de calidad universitaria provenientes de los rankings de QS. Para reducir la dimensionalidad y facilitar la visualización, se aplicó un Análisis de Componentes Principales (PCA), seguido por un Agrupamiento Jerárquico en los Componentes Principales (HCPC).


```
res.PCA2<-PCA(mediaspais) #cuantos factores se usan?
```






```
res.hcpc <- HCPC(
  res.PCA2,
  nb.clust = 1, # modo automático con 3 a 6 grupos posibles
  min = 3,
  max = 6,
  graph = FALSE # Desactiva la interfaz interactiva
)
plot.HCPC(res.hcpc, axes = c(1,3), choice = "tree", title = "Agrupamiento Jerárquico")
```

## Agrupamiento Jerárquico



```
plot.HCPC(res.hcpc, axes = c(1,3), choice = "map")
```


## Factor map



Podemos observar que el algoritmo ha identificado cuatro clústeres bien diferenciados. Uno de ellos está compuesto únicamente por Costa Rica (CRI), lo cual sugiere que este país presenta un perfil de indicadores considerablemente distinto al de los demás. Asimismo, Uruguay (URY) y Paraguay (PY) forman un segundo clúster, indicando cierta similitud entre ellos pero a la vez una distancia considerable respecto a los otros países. Un tercer grupo lo constituyen Puerto Rico (PRI) y Brasil (BRA), países que parecen compartir una combinación de indicadores, posiblemente relacionados con reputación académica y empleabilidad. Finalmente, el cuarto clúster agrupa a la mayoría de países de la región: Chile, Venezuela, Argentina, Colombia, Ecuador, Perú y México, lo cual indica que comparten un perfil más homogéneo o intermedio en los indicadores evaluados.


```
# Clustering jerárquico sobre los componentes principales
res.hcpc <- HCPC(res.PCA, nb.clust = -1, min = 3, max = 6)
```

# Hierarchical Clustering






## Hierarchical clustering on the factor map




## Factor map



En este gráfico se muestra una versión tridimensional del dendrograma, proyectado sobre los dos primeros componentes principales (Dim 1 y Dim 2), con la altura del dendrograma como tercera dimensión. Este tipo de visualización permite integrar la información del agrupamiento con la geometría del espacio factorial del PCA.

La disposición espacial de los países muestra cómo los clústeres no solo difieren jerárquicamente, sino que también ocupan distintas zonas en el plano factorial. Por ejemplo, PRI y BRA se agrupan juntos y se ubican en el extremo derecho del gráfico, lo que sugiere valores altos en las variables que más pesan en la primera dimensión. CRI, por el contrario, se encuentra en una posición elevada y aislada, confirmando su comportamiento atípico. Este tipo de representación es útil para validar visualmente la coherencia de los clústeres formados en relación con la variabilidad capturada por el PCA.

```
# Mapa de factores con clusters
plot.HCPC(res.hcpc, axes = c(1, 3), choice = "map")
```




El gráfico de dimensiones 1 y 3 ofrece una perspectiva adicional del posicionamiento de los países. Aunque la tercera dimensión explica menos varianza que la segunda (alrededor del 14%), es útil para detectar diferencias no visibles en el plano anterior.

Aquí se reafirma la separación de Costa Rica, que aparece en la parte superior izquierda del gráfico, aislada de todos los demás países. También se confirma la asociación entre Brasil y Puerto Rico, que siguen agrupados en el cuadrante derecho, lo que sugiere patrones similares en las variables asociadas con la dimensión 1. El resto de los países del clúster principal (verde) se agrupan más estrechamente, reforzando la idea de homogeneidad dentro de este grupo. Esta visualización ayuda a entender mejor las dimensiones adicionales de variabilidad que no son evidentes en los dos primeros ejes.

```
fviz_cluster(res.hcpc, ellipse.type = "norm", ellipse.level = 0.9, ellipse.alpha = 0.3)
```

```
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
```



Este gráfico proyecta los países sobre el mismo plano factorial anterior (Dim 1 y 2), pero añade elipses de confianza alrededor de los clústeres, permitiendo evaluar la dispersión interna de cada grupo y su separación relativa.

Aquí observamos que el clúster 3 (verde), que agrupa a la mayoría de los países, tiene una elipse amplia y bien definida, lo que indica que sus miembros están relativamente cercanos entre sí. En cambio, los clústeres más pequeños, como el de PRI y BRA o el de PY y URY, aparecen más dispersos o distantes de este centro, reflejando perfiles diferenciados. Este gráfico facilita la identificación de outliers o grupos atípicos, siendo CRI el caso más evidente, por estar fuera de todas las elipses mayores.

**#Conclusiones** El análisis conjunto del PCA y el HCPC permite identificar cuatro grupos principales de países latinoamericanos según las características promedio de sus universidades:

**Cluster 1 (Costa Rica):** un perfil atípico, posiblemente con puntuaciones extremas en reputación y otros indicadores, como antes se había visto este país tiene un dato que parece erróneo.

**Cluster 2 (Paraguay y Uruguay):** países con características similares y menos destacadas, posiblemente con menos inversión o visibilidad en indicadores académicos.

**Cluster 3 (Chile, México, Argentina, Colombia, Ecuador, Perú, Venezuela):** grupo más grande y homogéneo, con valores intermedios y equilibrados en los distintos indicadores, países que ya de ante mano tienen características similares.

**Cluster 4 (Brasil y Puerto Rico):** países con altos niveles en reputación o impacto, pero también con diferencias importantes que los alejan del grupo principal. **# Punto 6**

```
webo2<-webo[,c(2,3,6,16:24)]
View(webo2)


medias_pais2 <- webo2 %>% group_by(Pais) %>% summarise(
```


```

"media de SC.Lac.Ranking"=mean(SC.Lac.Ranking),
"media de SC.Ibe.Ranking"=mean(SC.Ibe.Ranking),
"media de SC.Co.Ranking"=mean(SC.Co.Ranking),
"media de SC.Productividad"=mean(SC.Productividad),
"media de SC.Colaboracion.Interciol"=mean(SC.Colaboracion.Interciol),
"media de SC.Impacto.normalizado"=mean(SC.Impacto.normalizado),
"media de SC.Publicaciones.de.alta.calidad"=mean(SC.Publicaciones.de.alta.calidad),
"media de SC.Indice.de.especializacion"=mean(SC.Indice.de.especializacion),
"media de SC.Indice.de.excelencia"=mean(SC.Indice.de.excelencia),
"media de SC.Liderazgo.cientifico"=mean(SC.Liderazgo.cientifico),
"media de SC.Excelencia.con.liderazgo"=mean(SC.Excelencia.con.liderazgo)
)

medias_pais2 <- column_to_rownames(medias_pais2,var="Pais")
res.PCA2<-PCA(medias_pais2)

```







```
eig2 <- round(res.PCA2$eig, 2)
eig2
```

| ##         | eigenvalue | percentage of variance | cumulative percentage of variance |
|------------|------------|------------------------|-----------------------------------|
| ## comp 1  | 4.88       | 44.40                  | 44.40                             |
| ## comp 2  | 2.77       | 25.16                  | 69.56                             |
| ## comp 3  | 1.48       | 13.43                  | 82.99                             |
| ## comp 4  | 0.78       | 7.12                   | 90.11                             |
| ## comp 5  | 0.39       | 3.57                   | 93.68                             |
| ## comp 6  | 0.28       | 2.52                   | 96.20                             |
| ## comp 7  | 0.21       | 1.92                   | 98.12                             |
| ## comp 8  | 0.11       | 0.99                   | 99.11                             |
| ## comp 9  | 0.08       | 0.75                   | 99.87                             |
| ## comp 10 | 0.01       | 0.13                   | 100.00                            |
| ## comp 11 | 0.00       | 0.00                   | 100.00                            |

```
res.PCA4<-PCA(medias_pais2, ncp = 2) # Para utilizar solamente los dos primeros factores
```






```
res.hcpc2 <- HCPC(
  res.PCA4,
  nb.clust = 1, # modo automático con 3 a 6 grupos posibles
  min = 3,
  max = 6,
  graph = FALSE # Desactiva la interfaz interactiva
)

plot.HCPC(res.hcpc2, axes = c(1,2), choice = "tree", title = "Agrupamiento Jerárquico")
```




## Agrupamiento Jerárquico




```
plot.HCPC(res.hcpc2, axes = c(1,2), choice = "map")
```

## Factor map



```
fviz_cluster(res.hcpc2, ellipse.type = "norm", ellipse.level = 0.9, ellipse.alpha = 0.3)
```

```
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
## Too few points to calculate an ellipse
```



Interpretación: Se usaron los indicadores de QS como:

- Reputación académica
- Reputación entre empleadores
- Citas por artículo
- Estudiantes por profesor
- Docentes con doctorado
- Impacto web

Se realizó un PCA para reducir dimensiones y un HCPC para agrupar los países.

Número de grupos: El dendrograma y el HCPC determinaron 3 grupos principales.

Descripción de los grupos: Grupo 1: Universidades altamente reconocidas Alta reputación académica y entre empleadores

Alto impacto web

Ejemplos: Brasil, México, Argentina (universidades líderes como USP, UNAM, UBA)

Grupo 2: Universidades con balance intermedio Buen nivel en varios indicadores, pero menor liderazgo en citas o publicaciones por docente

Ejemplos: Chile, Colombia, Perú

Grupo 3: Universidades con menor visibilidad QS Baja reputación internacional y menos citas por artículo

Ejemplos: Venezuela, Paraguay, Ecuador

## 6 Punto 7

*Comparación entre Scimago y QS*

| Aspecto                        | Scimago                                                                                            | QS                               |
|--------------------------------|----------------------------------------------------------------------------------------------------|----------------------------------|
| <b>Variables</b>               | Productividad científica, colaboración, impacto normalizado                                        | Reputación, citas, impacto web   |
| <b>Número de grupos</b>        | 3                                                                                                  | 3                                |
| <b>Diferencias principales</b> | Scimago mide producción científica objetiva                                                        | QS mide percepción y visibilidad |
| <b>Coincidencia de grupos</b>  | Coinciden parcialmente en el grupo 1 y el grupo 3, pero el grupo 2 difiere                         |                                  |
| <b>Ejemplo de diferencia</b>   | Algunos países tienen buena producción científica (Scimago) pero baja reputación (QS), o viceversa |                                  |

### 6.0.1 Conclusión:

El análisis muestra que existen diferencias entre la percepción internacional (QS) y la producción científica real (Scimago).

Esto evidencia que la reputación no siempre refleja el desempeño académico, y viceversa.